

SAPIENZA
UNIVERSITÀ DI ROMA

Rilevamento Non Supervisionato di Anomalie in Video Aerei mediante Reti Neurali Convoluzionali

Facoltà di Ingegneria dell'Informazione, Informatica e Statistica
Laurea Triennale in Informatica

Alessio Cavedal
Matricola 2087134

Relatore
Prof. Danilo Avola

Anno Accademico 2025/2026

Rilevamento Non Supervisionato di Anomalie in Video Aerei mediante Reti Neurali Convoluzionali

Tesi di Laurea. Sapienza Università di Roma

© 2026 Alessio Cavedal. Tutti i diritti riservati

Questa tesi è stata composta con LaTeX e la classe Sapthesis.

Email dell'autore: alessiocavedal15@icloud.com

«The purpose of computing is insight, not numbers»

— Richard Hamming

Sommario

Questa tesi studia il rilevamento non supervisionato di anomalie in video ripresi da drone. Sono stati costruiti due autoencoder convoluzionali, uno che lavora su un fotogramma alla volta e uno su brevi clip, addestrati solo su fotogrammi normali e con l'errore di ricostruzione come punteggio di anomalia. Il dataset è Drone-Anomaly: sette scene molto diverse fra loro e un solo modello per tutte. È un compito difficile per due motivi che si sommano: le anomalie non si conoscono in anticipo, e la varietà di ciò che è normale è molto ampia.

Fra i due modelli, quello a fotogramma singolo, nato come semplice controllo, si è rivelato in media almeno buono quanto quello su clip. In questo dominio vedere il movimento non basta: il modello su clip va meglio soprattutto nelle scene in cui l'anomalia è un movimento, e su UCSD Ped2, a camera fissa, supera quello a fotogramma singolo.

Un modello addestrato solo sul normale dovrebbe sbagliare dove c'è un'anomalia. Le misure mostrano invece che sbaglia soprattutto dove c'è più struttura da ricostruire, e che la grandezza che pesa di più è il contrasto del singolo fotogramma. Togliere il contrasto porta il modello globale da 58,4 a 65,3 di AUC, sul protocollo del lavoro che ha introdotto il dataset, e quasi tutto il guadagno si ottiene anche senza riaddestrare, dividendo per σ^2 l'errore di un modello già addestrato. Dove il contrasto è proprio il segno dell'anomalia, però, la correzione peggiora il risultato sette volte su sette, e una relazione statisticamente significativa permette di prevederlo.

I tre lavori che usano questo dataset non misurano l'AUC nello stesso modo, e sugli stessi punteggi i diversi protocolli danno numeri distanti fino a quasi trenta punti. Per questo il modello di questa tesi è confrontato con ciascun lavoro sul protocollo che quel lavoro dichiara. A parità di protocollo, un autoencoder convoluzionale molto più semplice arriva vicino a modelli basati su Transformer: 66,7 contro 67,0 con HSTforU, con un solo modello e senza riaddestrare, e 68,2 contro 68,6 con ANDT, con tredici modelli specializzati. Con un solo modello supera anche l'autoencoder convoluzionale del benchmark originale, 65,3 contro 62,5.

Per l'uso reale conta la decisione binaria. Il sistema rileva 22 dei 26 eventi anomali, l'84,6 %, con poco più di un falso allarme ogni mille fotogrammi, e il suo tasso di falsi positivi sta nella fascia dei metodi pubblicati. L'insieme di test però ha il 45 % di fotogrammi anomali: con una prevalenza dell'1 % la precision attesa sarebbe circa l'1,8 %. Su video in cui le anomalie non sono rare il sistema è già utile; per filmati reali, dove sono rare, il limite è del compito più che del modello.

Ripetuta senza regolazioni su UCSD Ped2, un dominio a camera fissa con una sola scena, la stessa pipeline ottiene risultati molto migliori. Il risultato complessivo è che in questo dominio la difficoltà sta soprattutto nel problema, più che nel modello: Drone-Anomaly sta all'estremo sfavorevole sia per l'assenza di supervisione sia per la varietà del normale. La correzione del contrasto funziona proprio perché agisce su questa difficoltà: rende i fotogrammi normali meno diversi fra loro.

Indice

1 Introduzione **1**
1.1 Contesto e motivazione 1
1.2 Il problema e le sue difficoltà 1
1.3 I risultati principali 2
1.4 Contributi 4

2 Fondamenti **5**
2.1 Rilevamento non supervisionato di anomalie nei video 5
2.2 Autoencoder convoluzionali 5
2.3 L'errore di ricostruzione come punteggio di anomalia 7
2.4 AUC-ROC e le sue aggregazioni 7
2.5 Le metriche della decisione binaria 8
2.6 Lo z-score per fotogramma 9

3 Stato dell'arte e posizionamento **10**
3.1 I tre lavori del benchmark 10
3.2 I due assi che rendono difficile il compito 11

4 Dati e protocollo di valutazione **14**
4.1 Drone-Anomaly 14
4.2 La prevalenza delle anomalie 15
4.3 UCSD Ped2 come prova esterna 15

5 Metodo **16**
5.1 La ricetta di addestramento 16
5.2 Le quattro varianti 16
5.3 Le due forme della correzione 17

6 Il confound del contrasto **19**
6.1 Che cosa misura davvero l'errore 19
6.2 Quale grandezza conta davvero 21
6.3 Lo spazio di misura contro il modello 22
6.4 Equivalenti in media, non intercambiabili per video 23
6.5 I limiti della correzione 23

7 Il trade-off del contrasto **25**
7.1 AUC_σ e la decorrelazione . . . 25
7.2 La relazione vale in entrambe le direzioni . . . 26
7.3 Quando si può usare la relazione . . . 27

8 Risultati su Drone-Anomaly **29**
8.1 Il guadagno della normalizzazione . . . 29
8.2 Sei normalizzazioni a confronto . . . 30
8.3 2D contro 3D . . . 31
8.4 L'effetto di un addestramento più lungo . . . 33
8.5 Il confronto con lo stato dell'arte . . . 33

9 Dalla metrica al compito **35**
9.1 Dall'ordinamento alla decisione . . . 35
9.2 Il regime a priori . . . 36
9.2.1 Le due granularità: quella del modello e quella della soglia . . . 36
9.3 Il regime a posteriori: la catena di Otsu . . . 36
9.4 Il divario dall'uso reale . . . 39

10 Verifica su UCSD Ped2 **41**
10.1 Impostazione e risultati . . . 41
10.2 La relazione fuori dominio . . . 43
10.3 L'effetto di un addestramento più lungo . . . 43
10.4 2D contro 3D . . . 44
10.5 La decisione su Ped2 . . . 44

11 Discussione, conclusioni e sviluppi futuri **45**
11.1 Discussione . . . 45
11.2 Conclusioni . . . 46
11.3 Sviluppi futuri . . . 46

A Riproducibilità **48**

B Tavole complete **49**

Bibliografia **52**

Capitolo 1

Introduzione

1.1 Contesto e motivazione

Con i droni è diventato economico riprendere dall'alto luoghi che prima si osservavano da terra, o che non si osservavano affatto: tratti di autostrada, linee ferroviarie, campi coltivati, impianti fotovoltaici, rotatorie. Il problema è che il materiale prodotto è molto più di quanto una persona riesca a guardare. Un'ora di ripresa a 30 fotogrammi al secondo corrisponde a centottomila immagini, e in quasi tutte non succede niente.

Per questo sarebbe utile un sistema che segnali da solo i punti in cui vale la pena guardare. La soluzione più ovvia sarebbe addestrare un rilevatore su esempi etichettati di ciò che si vuole trovare. In questo compito però non è possibile, perché le anomalie non si possono elencare in anticipo. Si può elencare ciò che è già successo, come un veicolo contromano, una persona dove non dovrebbe essere o un pannello danneggiato, ma non ciò che succederà. Un rilevatore supervisionato, quindi, trova solo ciò che si è saputo etichettare prima di iniziare.

Il rilevamento non supervisionato affronta il problema dal lato opposto. Invece di imparare che cos'è un'anomalia, il modello impara che cos'è il *normale*: viene addestrato solo su riprese regolari, e poi segnala come sospetto ciò che non riesce a riprodurre. Il vantaggio è che non serve sapere in anticipo che cosa si sta cercando. Il limite, su cui questa tesi torna spesso, è che il segnale usato non è l'anomalia ma la difficoltà di ricostruire il fotogramma, e le due cose coincidono meno di quanto ci si aspetterebbe.

Un sistema di questo tipo va quindi visto come una rete di sicurezza per ciò che non si può prevedere, non come un sostituto dei rilevatori addestrati su eventi noti (sezione 3.2).

1.2 Il problema e le sue difficoltà

Il dominio scelto è quello del dataset Drone-Anomaly, introdotto dal lavoro ANDT [4]: video ripresi interamente da drone su sette scene diverse. Il compito ha tre difficoltà, che si sommano. La prima è comune a tutto il rilevamento non supervisionato, le altre due sono specifiche di questo dominio.

1. *In addestramento ci sono solo fotogrammi normali.* Non è una scelta, è la definizione del compito: il modello non vede mai un'anomalia, quindi tutto ciò che impara sulle anomalie lo deve ricavare da ciò che non riesce a ricostruire.
2. *La camera è montata su un drone.* In una parte consistente delle riprese il drone si sposta, e con lui cambiano sfondo, prospettiva e scala. Secondo FTDMamba circa un terzo dei fotogrammi del dataset ha uno sfondo in movimento [7]. Molti metodi classici per la videosorveglianza, invece, assumono uno sfondo fermo, e su questa ipotesi si basano tecniche come la sottrazione dello sfondo.
3. *Le scene sono sette, molto diverse fra loro, e il modello è uno solo.* La stessa rete deve considerare normale sia una rotatoria in città sia un campo di risaie o una fila di pannelli solari.

La prima difficoltà dipende dall'assenza di supervisione. Le ultime due hanno lo stesso effetto: rendono molto varia la nozione di "normale" che il modello deve imparare. Supervisione e varietà del normale sono i due assi che, insieme, decidono quanto è difficile il compito, e Drone-Anomaly sta all'estremo sfavorevole di entrambi (sezione 3.2).

L'obiettivo della tesi è costruire un rilevatore non supervisionato di anomalie per video ripresi da drone, basato su autoencoder convoluzionali, e capire da che cosa dipendono i suoi risultati. Il lavoro risponde a quattro domande:

1. quale architettura funziona meglio in questo dominio: un autoencoder che guarda un fotogramma alla volta, o uno che guarda brevi clip?
2. che cosa misura davvero l'errore di ricostruzione, e come si può correggere?
3. come si colloca il risultato rispetto allo stato dell'arte, visto che i lavori che usano questo dataset misurano in modi diversi?
4. quanto è vicino il sistema a un uso reale?

Sullo sfondo c'è una domanda più generale: quanto della difficoltà sta nel modello e quanto nel problema. Per rispondere la tesi legge i risultati sui due assi, e ripete tutto su un dominio molto più semplice, UCSD Ped2.

1.3 I risultati principali

I modelli. Il lavoro è partito da due autoencoder convoluzionali con la stessa capacità: uno guarda un fotogramma alla volta (2D), l'altro brevi clip di sei fotogrammi (3D). Il 2D doveva servire solo a controllare la pipeline, ma su Drone-Anomaly si è rivelato in media almeno buono quanto il 3D. Vedere il movimento aiuta soprattutto nelle scene in cui l'anomalia è un movimento, come i veicoli contromano, mentre nelle ispezioni l'anomalia si vede spesso già in un solo fotogramma. Su UCSD Ped2, a camera fissa, è invece il 3D a fare meglio (sezione 8.3 e capitolo 10).

Che cosa misura l'errore. Un autoencoder addestrato solo su fotogrammi normali dovrebbe sbagliare dove c'è un'anomalia. In questo dominio, però, sbaglia soprattutto dove c'è più struttura da ricostruire, e la grandezza che conta di più è il

contrasto del singolo fotogramma, cioè quanto variano i valori dei suoi pixel. Usato da solo come punteggio di anomalia, il contrasto ha un'AUC che va da 12,6 a 96,7 a seconda del video: l'AUC vale 50 per un ordinamento casuale e 100 per uno perfetto (sezione 2.4). L'AUC del modello non corretto segue quella del contrasto, con una correlazione di +0,63. Togliere il contrasto, normalizzando ogni fotogramma oppure correggendo il punteggio di un modello già addestrato, scollega il punteggio dal contrasto: la correlazione scende a +0,09. Sul protocollo di ANDT la normalizzazione porta il modello 2D da 58,4 a 65,3 di AUC media, e quasi tutto il guadagno si ottiene anche senza riaddestrare (capitolo 6).

In pratica il contrasto è un **confound** (fattore di confondimento): un fotogramma normale ma molto contrastato sembra anomalo, mentre uno anomalo ma piatto può passare inosservato. Il **trade-off** è il compromesso che ne deriva: togliere il contrasto aiuta dove era solo un disturbo, e danneggia dove era proprio il segno dell'anomalia. La **relazione di trade-off** del capitolo 7 misura questo compromesso video per video.

Il confronto con lo stato dell'arte. I tre lavori che usano Drone-Anomaly non misurano l'AUC nello stesso modo, e sugli stessi punteggi i diversi protocolli danno numeri distanti fino a quasi trenta punti (sezione 2.4). Per questo il modello di questa tesi è confrontato con ciascun lavoro sul protocollo che quel lavoro dichiara. A parità di protocollo, un autoencoder convoluzionale molto più semplice arriva vicino a modelli basati su Transformer: 66,7 contro 67,0 con HSTforU, con un solo modello globale e senza riaddestrare, e 68,2 contro 68,6 con ANDT, con tredici modelli specializzati. Con un solo modello globale supera anche l'autoencoder convoluzionale del benchmark di ANDT, 65,3 contro 62,5. Solo sulla Macro per-video FTDMamba resta nettamente avanti (sezione 8.5).

L'uso reale. L'AUC dice quanto bene il modello ordina i fotogrammi, non se il sistema si può usare. Per questo si misurano anche le decisioni (capitolo 9). Su questo insieme di test il sistema rileva 22 dei 26 eventi anomali, con poco più di un falso allarme ogni mille fotogrammi. Il suo tasso di falsi positivi, il 29,6 %, sta nella fascia dei metodi pubblicati. L'insieme di test però ha il 45 % di fotogrammi anomali, molto più di un filmato reale, e quando le anomalie sono rare la precision scende di molto. Su video in cui le anomalie non sono rare il sistema è quindi già utile. Per filmati reali, invece, con i tassi di falsi positivi di questo benchmark nessun metodo pubblicato è ancora pronto: il limite è del compito più che del modello.

Dove sta la difficoltà. Tutti questi risultati si leggono meglio sui due assi del capitolo 3, la supervisione e la varietà del normale. Su UCSD Ped2, a camera fissa e con una sola scena, la stessa pipeline senza nessuna regolazione ottiene risultati molto migliori, sia in AUC sia sulle decisioni (capitolo 10). La difficoltà, quindi, sta soprattutto nel problema più che nel modello. È anche il motivo per cui la correzione funziona: togliendo il contrasto, rende i fotogrammi normali meno diversi fra loro, cioè agisce proprio sulla varietà del normale.

1.4 Contributi

I contributi della tesi coprono tutto il lavoro, dai modelli all'uso reale.

1. Il confronto fra due autoencoder convoluzionali con la stessa capacità, a fotogramma singolo e su clip, sullo stesso dominio e con la stessa ricetta. In questo dominio il primo è in media almeno buono quanto il secondo, e il vantaggio del secondo dipende dal tipo di anomalia (sezione 8.3 e capitolo 10).
2. La diagnosi di che cosa misura l'errore di ricostruzione: in questo dominio la grandezza che pesa di più è il contrasto del singolo fotogramma, più della texture e della lunghezza di compressione (sezione 6.2). Un esperimento controllato mostra poi che conta lo spazio in cui si misura l'errore, non il modello che lo produce, quindi quasi tutto il guadagno si ottiene senza riaddestrare (sezione 6.3).
3. La relazione di trade-off fra contrasto e guadagno, che funziona in entrambe le direzioni, con la previsione del danno che ne deriva e i suoi limiti (capitolo 7).
4. Un confronto con lo stato dell'arte fatto sul protocollo di ciascun lavoro. Mostra quanto i numeri dipendano dal modo di misurare, e colloca un modello semplice vicino a modelli molto più grandi (sezioni 2.4 e 8.5).
5. Una valutazione dell'uso reale, dalla graduatoria dei fotogrammi alla decisione per evento e per fotogramma (capitolo 9). Insieme, una lettura dei risultati sui due assi, misurata con la stessa pipeline su un dominio più semplice (capitolo 10).

Capitolo 2

Fondamenti

Questo capitolo presenta i concetti e gli strumenti utilizzati nella tesi.

2.1 Rilevamento non supervisionato di anomalie nei video

L'idea di fondo si riassume in due passi. Prima si addestra un modello a riprodurre bene i dati normali. Poi si assume che su un dato anomalo la riproduzione venga peggio, e si usa l'errore come punteggio di anomalia. Durante l'addestramento il modello non vede nessuna anomalia, e non si usa nessuna etichetta.

Il punto di forza di questo approccio è che non serve un catalogo di ciò che si cerca. Il punto debole, già accennato nella sezione 1.1, è che il sistema decide in base alla difficoltà di ricostruzione, non in base all'anomalia in sé. Le due cose coincidono solo se tutto ciò che rende un fotogramma difficile da ricostruire è anche anomalo, e il capitolo 6 mostra che in questo dominio non è così.

2.2 Autoencoder convoluzionali

Un autoencoder è formato da due parti. L'*encoder* comprime l'immagine in una rappresentazione più piccola, il *collo*, e il *decoder* prova a ricostruire l'immagine di partenza usando solo quella rappresentazione. L'encoder è una pila di convoluzioni: ogni layer fa scorrere un insieme di filtri sull'immagine e ne dimezza le dimensioni. Il decoder fa il percorso inverso con le convoluzioni trasposte, che a ogni layer raddoppiano le dimensioni. Fra un layer e l'altro c'è una **ReLU**, la funzione $\max(0, \cdot)$, che azzera i valori negativi e lascia passare quelli positivi: senza questa non linearità l'intera rete si ridurrebbe a una sola trasformazione lineare. Se il collo è più piccolo dell'immagine, la rete non può limitarsi a copiarla, ma deve tenere ciò che ricorre e scartare il resto. È in questo che consiste l'apprendimento del "normale".

La figura 2.1 mostra le due architetture usate. Sono entrambe convoluzionali e simmetriche, e la differenza principale è che la 2D lavora su un fotogramma alla volta, mentre la 3D lavora su una *clip* di sei fotogrammi consecutivi. La **convoluzione 3D** è l'estensione diretta di quella 2D: il filtro scorre non solo in larghezza e in altezza, ma anche nel tempo. Così ogni valore in uscita dipende da un piccolo blocco di

pixel vicini, sia nello spazio sia nei fotogrammi adiacenti. È questo che permette al modello 3D di vedere il movimento, che un fotogramma isolato non contiene.

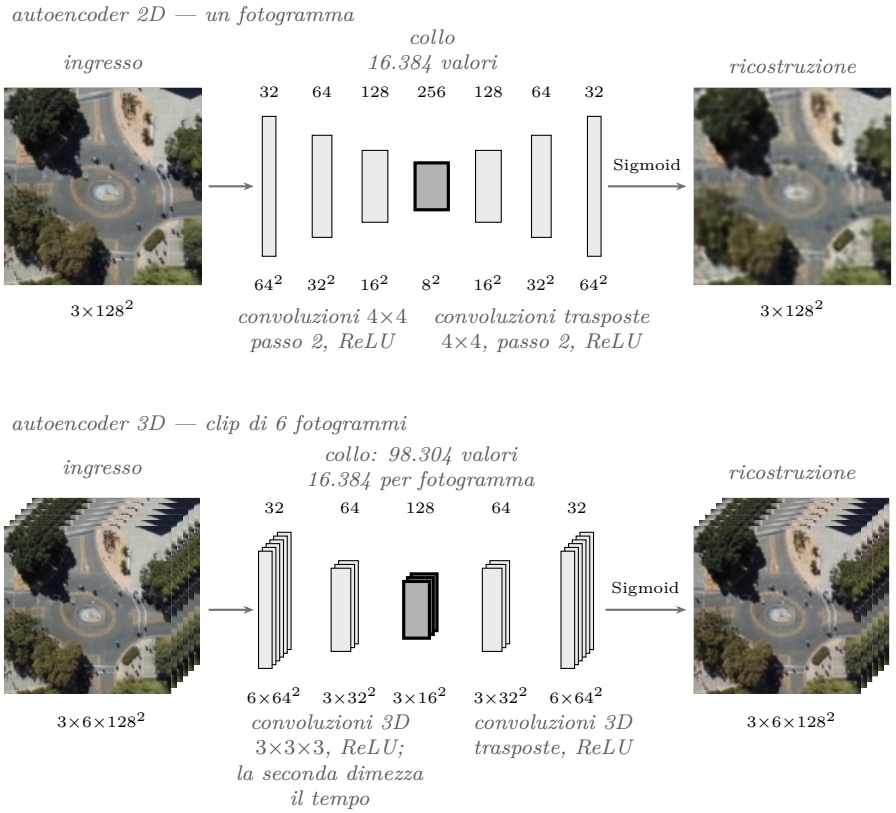


Figura 2.1. Le due architetture, con un'immagine vera che entra e la sua ricostruzione che esce. Per il 2D l'immagine è un fotogramma normale di un video di test di Bike Roundabout, per il 3D la clip di sei fotogrammi che comincia da lì. Sopra ogni blocco ci sono i canali, sotto il lato delle mappe; nel 3D ogni blocco è una pila, con un rettangolo per ogni istante di tempo. L'encoder riduce, il collo è il punto più stretto, il decoder ricostruisce. Le ricostruzioni sono quelle dei modelli senza normalizzazione dell'input (sezione 5.2). Il 2D conserva alberi, strade e l'anello della rotatoria, e perde le persone; il 3D, che nel collo tiene una griglia di 16×16 invece che di 8×8, è più nitido.

Il confronto fra le due architetture è corretto solo se nessuna delle due ha più spazio nel collo, quindi sono state controllate le dimensioni. Il collo del 2D contiene $256 \times 8 \times 8 = 16.384$ valori per un fotogramma di $3 \times 128 \times 128 = 49.152$. Quello del 3D ne contiene $128 \times 3 \times 16 \times 16 = 98.304$ per una clip di sei fotogrammi, cioè di nuovo 16.384 per fotogramma. Entrambi comprimono l'ingresso di un fattore 3, quindi la differenza fra i loro risultati (sezione 8.3) non dipende da quanta informazione ciascuno riesce a trattenere.

2.3 L'errore di ricostruzione come punteggio di anomalia

Il punteggio di un fotogramma è l'errore quadratico medio fra il fotogramma e la sua ricostruzione, calcolato su tutti i pixel e sui tre canali di colore:

$$e = \frac{1}{3HW} \sum_{c,i,j} \left(r_{cij} - x_{cij}\right)^2, \tag{2.1}$$

dove x è il fotogramma, r la ricostruzione, e H, W le sue dimensioni. Un punteggio alto dovrebbe indicare un fotogramma che il modello non sa riprodurre, e quindi un'anomalia.

Il capitolo 6 mette alla prova proprio questa ipotesi, e la formula fa già intuire dove nasce il problema. L'errore e è una media di differenze al quadrato fra valori di pixel, quindi cresce con l'*ampiezza* di quei valori. Un fotogramma molto contrastato offre differenze più grandi da sbagliare rispetto a uno piatto, anche se la rete lo ha capito altrettanto bene.

2.4 AUC-ROC e le sue aggregazioni

Per trasformare un punteggio continuo in una decisione servirebbe una soglia. La curva ROC evita di sceglierne una. Si fanno scorrere *tutte* le soglie possibili e, per ciascuna, si riporta su un grafico il tasso di veri positivi in funzione di quello di falsi positivi. L'**AUC-ROC**, che nel seguito sarà chiamata semplicemente AUC, è l'area sotto la curva che si ottiene. È la probabilità che un fotogramma anomalo preso a caso abbia un punteggio più alto di un fotogramma normale preso a caso. Nella tesi sarà riportata in punti percentuali.

L'AUC vale 100 per un ordinamento perfetto e 50 per uno casuale, e scende sotto 50 quando l'ordinamento è rovesciato in modo sistematico. In questa tesi il caso capita spesso, e non va scambiato per rumore: un'AUC di 30 non viene da un modello che sbaglia a caso, ma da uno che ordina bene, però al contrario. Poiché considera tutte le soglie insieme, l'AUC non cambia se al punteggio si applica una trasformazione monotona crescente. Per lo stesso motivo non dice dove mettere la soglia: due punteggi con la stessa AUC possono richiedere soglie molto diverse. Per questo il capitolo 9, quando passa alla decisione binaria, riparte da capo.

La difficoltà vera non sta nella definizione ma nell'*aggregazione*. I 22 video di test si distribuiscono su sette scene, e a seconda di come si raggruppano gli stessi punteggi danno numeri molto diversi. Sul modello 3D normalizzato, per esempio, si va da 36,8 a 65,5: quasi trenta punti di distanza. Le sette aggregazioni implementate, chiamate *protocolli*, sono nella tabella 2.1. La prima mette tutti i 35.843 fotogrammi di test in un'unica graduatoria, e non è usata in nessun confronto. Dipende infatti dalle differenze di scala fra un video e l'altro, cioè da quanto un video produce errori grandi in assoluto, e questa non è una proprietà del rilevatore.

Tabella 2.1. I sette protocolli di misura. “Micro” significa che i fotogrammi entrano in un’unica graduatoria prima di calcolare l’AUC; “Macro” che si calcola un’AUC per ogni unità e poi se ne fa la media. Il min-max è una normalizzazione del punteggio dentro ciascun video, che azzera le differenze di scala fra video. I risultati della tesi si basano su due protocolli: la Micro per-scena, quella di ANDT, e la Macro per-scena, usata come controllo.

protocollo	come aggrega	usato da
Micro dataset	tutti i fotogrammi in un’unica graduatoria	—
Micro per-scena	graduatoria dentro la scena, poi media delle 7	ANDT
Micro per-scena +minmax	come sopra, su punteggi min-max per video	HSTforU
Micro dataset +minmax	graduatoria unica su punteggi min-max	FTDMamba
Micro dataset +minmax (PSNR)	come sopra, in scala logaritmica	FTDMamba
Macro per-video	media delle AUC dei 22 video	FTDMamba
Macro per-scena	per video, poi per scena, poi media delle 7	controllo

Il PSNR (*peak signal-to-noise ratio*) è l’errore quadratico medio espresso in scala logaritmica, rispetto al valore massimo che un pixel può assumere: $\mathrm{PSNR} = 10\log_{10}(\max^2/e)$. Cresce quando l’errore cala, quindi come punteggio di anomalia va usato con il segno invertito. È una trasformazione monotona dell’errore, quindi da sola non cambierebbe l’AUC. La cambia solo insieme al min-max per video, perché la scala logaritmica modifica le proporzioni prima che il min-max le riscali.

2.5 Le metriche della decisione binaria

L’AUC misura una graduatoria. Quando invece si fissa una soglia e si dichiara anomalo tutto ciò che la supera, ogni fotogramma finisce in una delle quattro caselle della tabella 2.2. Tutte le metriche del capitolo 9 si ricavano da lì.

Tabella 2.2. La matrice di confusione. I nomi sono dal punto di vista della classe “anomalo”: un *falso positivo* è un fotogramma normale segnalato per errore.

		verità di riferimento	
		anomalo	normale
decisione	segnalato	VP (vero positivo)	FP (falso positivo)
	non segnalato	FN (falso negativo)	VN (vero negativo)

Da queste quattro quantità si ottengono le cinque misure usate nel seguito:

$$\mathrm{recall} = \frac{VP}{VP+FN}, \qquad \mathrm{precision} = \frac{VP}{VP+FP}, \qquad \mathrm{FPR} = \frac{FP}{FP+VN}, \tag{2.2}$$

$$\mathrm{F1} = 2\,\frac{\mathrm{precision}\cdot\mathrm{recall}}{\mathrm{precision}+\mathrm{recall}}, \qquad \mathrm{OA} = \frac{VP+VN}{VP+VN+FP+FN}. \tag{2.3}$$

Il **recall** è la quota di anomalie che il sistema intercetta. La **precision** è la quota di segnalazioni che erano davvero anomalie. Il **tasso di falsi positivi** (FPR) è la quota di fotogrammi normali segnalati per errore. L'**F1** è la media armonica di precision e recall, e penalizza chi va bene in una sola delle due. L'**accuratezza complessiva** (OA) è la frazione di fotogrammi classificati correttamente. Alcuni lavori riportano infine l'**EER** (*equal error rate*), cioè il punto della curva ROC in cui il tasso di falsi negativi, $1 - \mathrm{recall}$, è uguale all'FPR.

Precision e prevalenza. La precision dipende dalla quota di anomalie presenti nei dati, l'FPR no, e questa differenza è la base di tutto il capitolo 9. Si vede dalle definizioni. Il denominatore dell'FPR, $FP + VN$, contiene solo fotogrammi normali: se il sistema ne segnala il 30 %, quella percentuale resta la stessa qualunque sia la quota di anomalie nel filmato. Il denominatore della precision, $VP + FP$, mescola invece le due classi, e quando le anomalie diventano rare i falsi positivi prendono il sopravvento. Lo stesso rilevatore può quindi avere una precision alta su un insieme di test ricco di anomalie e una precision molto bassa su un filmato reale, senza che nel modello sia cambiato nulla.

2.6 Lo z-score per fotogramma

Un'operazione molto importante è la normalizzazione di ciascun fotogramma:

$$z(x) = \frac{x-\mu}{\sigma}, \tag{2.4}$$

dove μ e σ sono la media e la deviazione standard dei pixel di quel fotogramma. Dopo la trasformazione ogni fotogramma ha media 0 e deviazione standard 1, cioè lo stesso contrasto di tutti gli altri. In tutta la tesi μ e σ sono calcolate su tutti i valori RGB del fotogramma insieme, e σ è la misura di contrasto usata in ogni capitolo.

La formula è quella della standardizzazione classica, ma le statistiche vengono da un'altra parte. Di solito si normalizza ogni *variabile* usando tutti i campioni del dataset, e media e deviazione standard si stimano una volta sola, in addestramento. Qui invece si normalizza ogni *fotogramma* usando i suoi stessi pixel: le statistiche si ricalcolano anche in fase di test, e non si usano mai informazioni che vengono da altri fotogrammi.

Di conseguenza in questa tesi l'espressione "z-score sull'input" indica una normalizzazione per fotogramma. Ne segue anche la risposta a un dubbio che questa scelta solleva spesso, cioè se ricalcolare le statistiche in fase di test è una fuga di informazione (*leakage*). Non lo è, perché la trasformazione usa solo i pixel del fotogramma che sta normalizzando: non usa le sue etichette, né le statistiche di altri fotogrammi o dell'insieme di addestramento. Non ci sono parametri da stimare, quindi non c'è nulla che possa passare dal test all'addestramento.

Capitolo 3

Stato dell'arte e posizionamento

3.1 I tre lavori del benchmark

Drone-Anomaly è stato introdotto da ANDT [4], che insieme al dataset propone anche un modello. ANDT divide i fotogrammi consecutivi in *tubelet*, cioè piccoli blocchi che coprono una regione dell'immagine per alcuni fotogrammi di fila. Un encoder *Transformer* ne impara le rappresentazioni, e un decoder le usa per predire il fotogramma successivo. Un Transformer è un'architettura che mette in relazione ogni parte dell'ingresso con tutte le altre, invece di guardare solo i pixel vicini come fa una convoluzione. Ogni parte viene poi pesata in base a quanto conta per le altre. Lo stesso lavoro pubblica anche un benchmark di metodi già esistenti, fra cui un autoencoder convoluzionale, che è il termine di paragone più vicino al modello costruito in questa tesi.

HSTforU [6] usa lo stesso dataset come prova, insieme a tre dataset ripresi da terra. La sua architettura è un encoder Transformer a più stadi, che produce mappe di caratteristiche a più scale, collegato a un Transformer spazio-temporale gerarchico e a un decoder con struttura a U.

FTDMamba [7] è il lavoro più recente, e affronta direttamente il problema dello sfondo in movimento. Quando il drone si muove, il movimento degli oggetti e quello causato dalla camera si sovrappongono, e i metodi esistenti rischiano di scambiare il secondo per il primo. FTDMamba propone un modulo che separa i due contributi nel dominio della frequenza, e un modulo basato su *Mamba* per la dinamica temporale. Mamba è un'architettura per sequenze più recente del Transformer. Tiene una memoria compatta di ciò che ha già visto e la aggiorna fotogramma dopo fotogramma, con un costo che cresce più lentamente quando la sequenza si allunga.

Tutti e tre i lavori seguono il paradigma della predizione: invece di ricostruire il fotogramma che ricevono, predicono il successivo a partire dai precedenti, e usano come punteggio l'errore di predizione. Il lavoro di questa tesi invece è a ricostruzione, come l'autoencoder convoluzionale del benchmark di ANDT, che viene superato con un solo modello globale (sezione 8.5). La differenza conta: ANDT confronta i due paradigmi sulla propria architettura, e sulla scena Highway la predizione va meglio della ricostruzione [4].

C'è poi una seconda differenza, meno evidente, che riguarda il modo di misurare. I tre lavori non aggregano l'AUC nello stesso modo. ANDT riporta valori per scena calcolati sul punteggio grezzo. HSTforU e FTDMamba normalizzano i punteggi dentro ciascun video prima di aggregarli, e FTDMamba riporta soprattutto valori sull'intero dataset, con valori per scena solo per le quattro scene di traffico. Mettere i loro numeri uno accanto all'altro senza tenerne conto significa confrontare grandezze diverse. Nella sezione 8.5 si riporta il confronto completo, misurando il modello di questa tesi, blocco per blocco, con il protocollo dichiarato da ciascun lavoro.

3.2 I due assi che rendono difficile il compito

La prestazione di questi sistemi dipende da due fattori:

Primo asse: la supervisione

I sistemi usati nelle applicazioni operative sono per lo più supervisionati: sanno in anticipo che cosa stanno cercando. Questa tesi e i tre lavori del benchmark invece no. La tabella 3.1 mette a confronto le due situazioni.

Tabella 3.1. Il primo asse: sistemi supervisionati e non supervisionati a confronto.

	sistemi supervisionati	questa tesi e i tre lavori
supervisione	su classi note	nessuna: in addestramento solo normale
insieme degli eventi	chiuso, definito a priori	aperto — "qualcosa di insolito"
che cosa definisce l'anomalia	una regola di dominio	la statistica dell'errore

In pratica è uno scambio. Da una parte ci sono prestazioni alte, ma solo su ciò che era previsto. Dall'altra c'è la possibilità di segnalare qualunque anomalia, almeno in linea di principio, ma con un segnale che misura la difficoltà di ricostruzione (sezione 2.1). I due approcci quindi non sono uno giusto e uno sbagliato: rispondono a domande diverse. Il rilevamento non supervisionato nasce dal fatto che le anomalie arbitrarie non si possono etichettare in anticipo, mentre i sistemi supervisionati aggirano il problema restringendo il compito a ciò che si sa elencare.

Da qui viene una delle domande della tesi (sezione 1.2): se il segnale è la difficoltà di ricostruzione, bisogna capire che cosa rende un fotogramma difficile da ricostruire. Ne parlano i capitoli 6 e 7.

Secondo asse: quanto è vario il "normale"

La prestazione peggiora man mano che la varietà del normale aumenta, come mostra la figura 3.1. A un estremo c'è l'ispezione industriale di MVTec AD [2], dove l'inquadratura è controllata, all'altro c'è Drone-Anomaly. In mezzo ci sono UCSD Ped2 [8], con camera fissa e una sola scena, e l'ispezione all'aperto di MIAD [1]. In Drone-Anomaly il normale è vario per tre ragioni insieme: le sette scene sono molto diverse fra loro, un solo modello deve coprirle tutte, e in una parte consistente delle

riprese la camera si sposta. Secondo FTDMamba hanno uno sfondo in movimento 9 dei 22 video di test, e in tutto circa il 35 % dei fotogrammi del dataset [7].

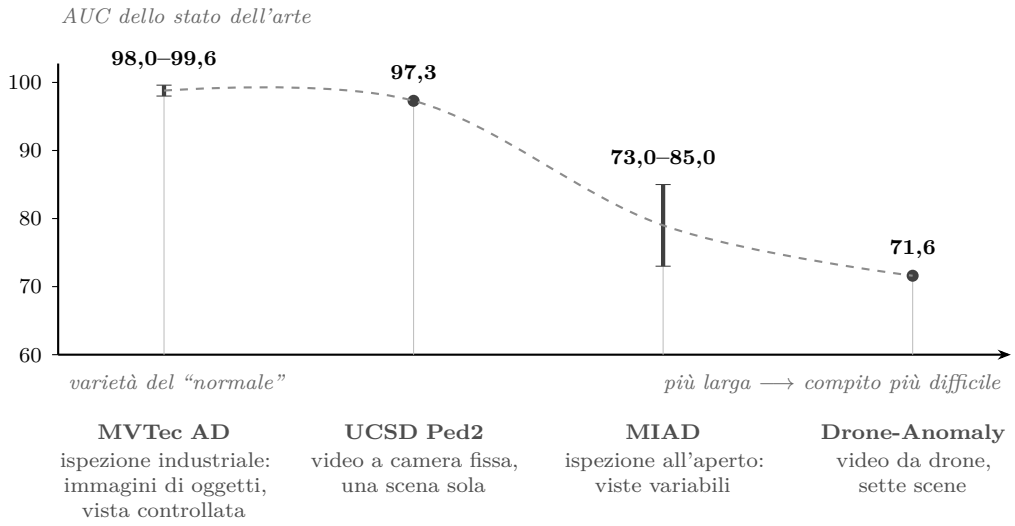


Figura 3.1. Il gradiente di difficoltà. Più il "normale" è vario, più la prestazione scende. L'asse verticale è in scala. Il valore di UCSD Ped2 è quello di HSTforU [6], quello di Drone-Anomaly è lo stato dell'arte pubblicato da FTDMamba [7]. Gli intervalli di MVTec AD e di MIAD vengono dal lavoro che introduce MIAD [1], e sono le AUC medie degli stessi metodi dello stato dell'arte sui due dataset.

Drone-Anomaly sta quindi all'estremo sfavorevole di entrambi gli assi: è non supervisionato e ha un normale molto vario. I risultati di questa tesi vanno letti tenendo conto di questa posizione.

I due assi però sono in buona parte indipendenti, e questo evita una conclusione affrettata. Se fossero lo stesso asse, il solo fatto che il compito sia non supervisionato basterebbe a spiegare un risultato basso. Non basta, perché anche MVTec AD è non supervisionato, eppure lì le AUC dello stato dell'arte stanno fra 98,0 e 99,6 [1], dato che il secondo asse gli è favorevole. Quindi non è la supervisione, da sola, a decidere se l'approccio funziona.

I due assi nel resto della tesi

I due assi non servono solo a collocare il lavoro: sono la chiave con cui si leggono tutti i risultati dei capitoli successivi.

- Il livello dei risultati su Drone-Anomaly, di questa tesi e dello stato dell'arte, va letto su questa scala, cioè all'estremo sfavorevole di entrambi gli assi.
- Ridurre la varietà del normale significa intervenire proprio sulla causa della difficoltà, e non solo pre-elaborare i dati. È quello che fa la correzione studiata nei capitoli 6 e 7: togliendo il contrasto, rende i fotogrammi normali meno diversi fra loro. Lo stesso fa, in modo più costoso, la specializzazione dei modelli sulle singole sequenze (sezione 8.5).

- Il secondo asse si può anche misurare: su UCSD Ped2, a camera fissa e con una sola scena, la stessa pipeline va molto meglio (capitolo 10).
- Il primo asse spiega perché la distanza dall'uso reale è comune a tutti i metodi pubblicati (sezione 9.4).

Il gradiente, quindi, indica la grandezza che governa la difficoltà del compito, e la tesi studia un modo di agire proprio su questa grandezza.

Capitolo 4

Dati e protocollo di valutazione

4.1 Drone-Anomaly

Il dataset è organizzato in sette scene. Ogni scena è divisa in una o più sequenze, tredici in tutto, e ogni sequenza contiene a sua volta delle riprese numerate. Le riprese di addestramento contengono solo materiale normale. Quelle di test contengono sia fotogrammi normali sia anomali, con un'etichetta per ogni fotogramma. In tutto ci sono 37 riprese di addestramento e 22 di test.

Nel resto della tesi si chiama *video* ciascuna delle 22 riprese di test. La figura 4.1 mostra quanto sono diverse le sette scene.

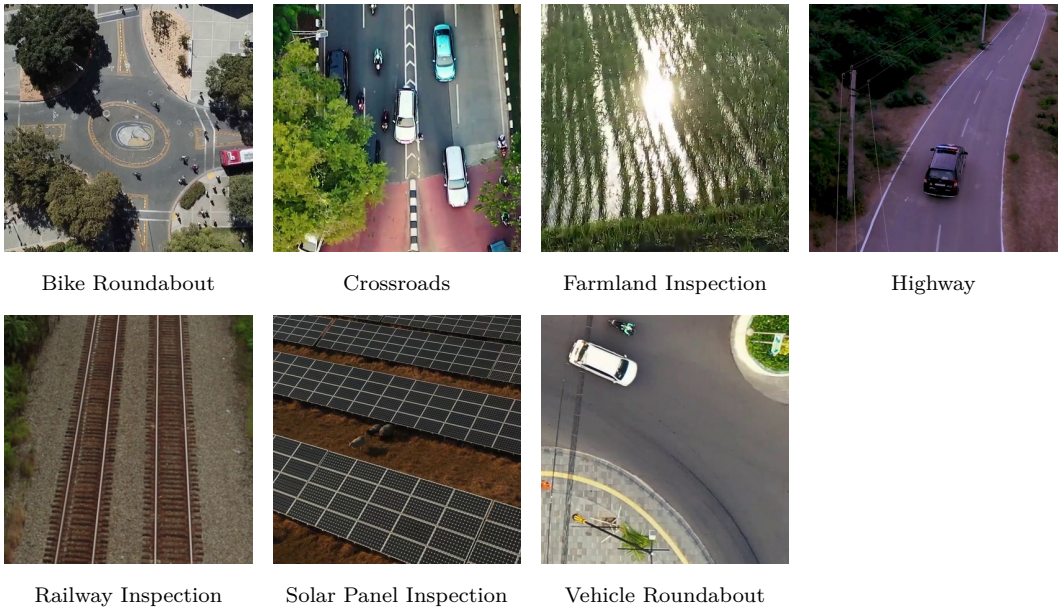


Figura 4.1. Le sette scene, con un fotogramma di test per ciascuna. La distanza fra una rotatoria in città e un campo di risaie è il problema della sezione 1.2: un solo modello deve considerarle normali entrambe.

La risoluzione originale è 640×640 a 30 fotogrammi al secondo, e i modelli lavorano su immagini ridotte a 128×128 RGB.

4.2 La prevalenza delle anomalie

L'insieme di test contiene 16.119 fotogrammi anomali su 35.843, cioè il 45 % del totale. È un valore molto alto, e cambia molto da una scena all'altra, come mostra la tabella 4.1.

Tabella 4.1. Composizione dell'insieme di test. La prevalenza va dal 3,4 % di Farmland al 65,2 % di Bike Roundabout, e Bike Roundabout da sola rappresenta più della metà dei fotogrammi.

scena	fotogrammi	quota del test	prevalenza
Bike Roundabout	18.427	51,4 %	65,2 %
Crossroads	6.244	17,4 %	27,0 %
Highway	2.820	7,9 %	17,6 %
Vehicle Roundabout	2.633	7,3 %	37,0 %
Solar Panel Inspection	2.450	6,8 %	32,3 %
Farmland Inspection	2.387	6,7 %	3,4 %
Railway Inspection	882	2,5 %	7,7 %
totale	35.843	100 %	45,0 %

Questo dato è presentato prima di qualunque metrica perché è la base di tutto il capitolo 9. In un uso reale la prevalenza è molto più bassa: in un vero filmato di sorveglianza i fotogrammi anomali sono una piccolissima parte del totale. Per questo le metriche che dipendono dalla prevalenza, a partire dalla precision, vanno lette come proprietà di *questo* insieme di test, e non come la prestazione che ci si può aspettare sul campo.

4.3 UCSD Ped2 come prova esterna

Per capire se ciò che si misura è una proprietà del metodo o del dominio, tutta la pipeline è stata ripetuta su UCSD Ped2 [8]: camera fissa, una sola scena e anomalie ben definite, come biciclette e piccoli veicoli su un vialetto pedonale. Serve anche come verifica di coerenza: se il metodo funziona da qualche parte, deve funzionare qui.

Dei dodici video di test, quattro sono interamente anomali: per questi l'AUC non si può calcolare, quindi le metriche per video si calcolano sugli altri otto. L'unica cosa adattata a Ped2 è la durata dell'addestramento, per la ragione spiegata nella sezione 10.1.

Ped2 è un dominio più facile di Drone-Anomaly, e la figura 3.1 mostra quanto. Se qualcosa funziona su Ped2, non è detto che funzioni anche su domini più vari. Per questo Ped2 serve a verificare se ciò che è misurato su Drone-Anomaly si trasferisce, non a dimostrare che vale in generale. I risultati sono nel capitolo 10.

Capitolo 5

Metodo

5.1 La ricetta di addestramento

Tutti i modelli di questa tesi sono addestrati con la stessa configurazione. Le immagini sono ridotte a 128×128 pixel RGB. L'addestramento dura 5 epoche, dove un'*epoca* è un passaggio completo su tutto l'insieme di addestramento. A ogni iterazione la rete vede un *lotto* di esempi, 64 fotogrammi per le varianti 2D e 8 clip per quelle 3D, e ne aggiorna i pesi per ridurre l'errore quadratico medio. L'aggiornamento dei pesi lo fa Adam [5], un ottimizzatore molto diffuso per reti di questo tipo, con un *tasso di apprendimento* di 10^{-3}, cioè l'ampiezza dei passi con cui i pesi vengono spostati. Il *seed* 42 fissa i generatori di numeri casuali, che decidono come vengono inizializzati i pesi e in che ordine vengono presentati gli esempi: così, rieseguendo l'addestramento, si ottengono gli stessi pesi.

Le clip sono di 6 fotogrammi consecutivi. In addestramento se ne estrae una ogni 3 fotogrammi, quindi clip successive si sovrappongono per metà. In test se ne estrae una ogni 6, senza sovrapposizione, così ogni fotogramma riceve un solo punteggio. Gli ultimi fotogrammi di un video che non bastano a riempire una clip restano senza punteggio, quindi il 3D valuta qualche fotogramma in meno del 2D: su Farmland, per esempio, 2.382 invece di 2.387. Una clip, infine, non attraversa mai il confine fra due riprese: conterrebbe uno stacco che nel video non esiste, e il modello lo imparerebbe come normale.

Hardware. Tutti i numeri di questa tesi sono stati prodotti su un MacBook Air con processore Apple M4, usando MPS, il sistema di calcolo su GPU dei processori Apple. L'unica eccezione è il controllo con l'addestramento lungo della sezione 8.4, eseguito su una GPU NVIDIA con CUDA, ed è segnalato dove compare. I due sistemi non danno risultati identici bit per bit, quindi fra l'uno e l'altro si confrontano solo le *differenze*, non i valori assoluti (appendice A).

5.2 Le quattro varianti

Le varianti confrontate sono quattro, organizzate in due coppie: una 2D e una 3D, ciascuna con e senza normalizzazione dell'input. La tabella 5.1 le riporta insieme ai loro risultati, che servono già nei capitoli 6 e 7.

Tabella 5.1. Le quattro varianti e i loro risultati. Dentro ogni coppia cambia solo l'input, e di conseguenza l'ultimo layer (Sigmoid con l'input in $[0, 1]$, lineare con quello normalizzato), quindi la differenza si può attribuire alla normalizzazione. Lo z-score è sempre per fotogramma (sezione 2.6); la colonna "clip" indica quanti fotogrammi consecutivi riceve il modello.

variante	input	clip	Micro per-scena	Macro per-scena
2D senza z	RGB in $[0, 1]$	1	58,4	53,9
2D con z	z-score	1	65,3	62,8
3D senza z	RGB in $[0, 1]$	6	48,5	47,2
3D con z	z-score	6	64,9	58,6

Le coppie servono a isolare l'effetto della normalizzazione, a parità di tutto il resto. Se si confrontasse il modello normalizzato con un modello di partenza addestrato in un altro modo, si cambierebbero due cose insieme, e un risultato migliore non direbbe da dove viene. Il capitolo 6 porta questa separazione fino in fondo (sezione 6.3).

Senza normalizzazione il 3D sta dieci punti sotto il 2D in Micro per-scena; con la normalizzazione la distanza quasi si annulla (64,9 contro 65,3), mentre in Macro per-scena resta di circa quattro punti. Il confronto fra le due architetture ha una sezione propria, la 8.3, perché scena per scena le differenze sono più grandi di quanto la media lasci vedere.

5.3 Le due forme della correzione

La normalizzazione si può applicare in due punti diversi:

- **z-score sull'input**: si applica l'equazione (2.4) al fotogramma prima di darlo alla rete, cioè gli si sottrae la media μ e lo si divide per σ. In questo caso la rete va riaddestrata. Sono le varianti 2D con z e 3D con z.
- **z-score sul punteggio**: si prende l'errore e di un modello addestrato senza normalizzazione e lo si divide per σ^2, senza toccare nessun peso e senza nessun addestramento.

Sull'errore le due operazioni hanno lo stesso effetto. Se r è la ricostruzione del fotogramma x, l'errore misurato nello spazio normalizzato è

$$e_z = \text{media}\left[\left(\frac{r-\mu}{\sigma} - \frac{x-\mu}{\sigma}\right)^2\right] = \text{media}\left[\left(\frac{r-x}{\sigma}\right)^2\right] = \frac{e}{\sigma^2}, \tag{5.1}$$

perché σ è costante dentro il fotogramma ed esce dalla media. Misurare l'errore nello spazio normalizzato equivale quindi a dividerlo per σ^2: il fotogramma viene diviso per σ, e l'errore, che è un quadrato, per σ^2.

Nel passaggio anche la media μ si cancella. Questo spiega perché una normalizzazione che si limita a centrare il fotogramma, cioè a togliere la media senza dividere per σ, dà quasi lo stesso risultato del modello di partenza: 58,9 contro 58,4 (è una delle normalizzazioni confrontate nella sezione 8.2). Togliere la media non toglie il contrasto, ed è il contrasto il canale che conta.

L'identità vale per la trasformazione dell'errore, ma lo z-score sull'input cambia anche i pesi della rete, che viene riaddestrata. In media le due forme danno risultati molto simili, ma sul singolo video non sono intercambiabili (sezione 6.4).

Il costo della correzione. Lo z-score sul punteggio non costa nulla, perché si applica all'errore di un modello che esiste già. Lo z-score sull'input richiede invece un nuovo addestramento. Sulla singola esecuzione, la forma senza addestramento recupera l'88 % del guadagno del modello riaddestrato in Micro per-scena e il 99 % in Macro per-scena (tabella 6.2). In una fase precedente del lavoro, ripetendo il confronto con quattro seed diversi, il rapporto va dal 77 % al 145 %, a seconda della metrica. Sulle metriche calcolate sull'intero dataset, anzi, la correzione senza addestramento fa meglio del riaddestramento (sezione 8.5).

Capitolo 6

Il confound del contrasto

6.1 Che cosa misura davvero l'errore

Il punto di partenza è una misura semplice: quanto l'errore di ricostruzione segue la struttura visiva del fotogramma, anche quando l'anomalia non c'è. Se un autoencoder sbagliasse solo dove c'è un'anomalia, sui fotogrammi normali questo legame non dovrebbe esserci.

Per misurarlo è stata calcolata, dentro ciascun video e solo sui fotogrammi normali, la correlazione fra l'errore di ricostruzione e la *texture* del fotogramma, cioè quanto l'immagine cambia da un pixel a quello vicino. La texture è alta su un campo di risaie o sul fogliame, e bassa su una superficie liscia; la definizione precisa è nella sezione 6.2. La mediana di questa correlazione sui 22 video è +0,90, quindi l'errore segue la texture molto da vicino. Su Farmland Inspection arriva a 0,98, e su quella scena l'AUC del modello non corretto è 29,8: sotto 50, cioè la graduatoria è rovesciata in modo sistematico.

Le correlazioni di questo capitolo sono di Spearman. La **correlazione di Spearman** è la correlazione di Pearson calcolata sui *ranghi* invece che sui valori. Vale +1 quando le due grandezze crescono insieme, −1 quando una cresce mentre l'altra cala, e 0 quando non c'è nessun legame monotono. Si usano i ranghi perché fra errore e texture non ci si aspetta un legame lineare. Quello che interessa sapere è se le due grandezze ordinano i fotogrammi allo stesso modo, che è la stessa domanda a cui risponde l'AUC. La si calcola dentro il video perché fra video diversi il legame sarebbe confuso dalle differenze di scala. La si calcola solo sui fotogrammi normali perché interessa sapere se il legame resta anche quando l'anomalia non c'è: solo così si tratta davvero di un confound, e non di un effetto dell'anomalia stessa.

La figura 6.1 mostra che cosa significa su Farmland. Dei tre fotogrammi, quello che il modello non corretto ricostruisce peggio è il 1300: una risaia normale ma molto contrastata, con una σ quasi tripla rispetto agli altri due. Il suo punteggio è 5,4 volte quello del fotogramma anomalo 1770, dove il veicolo che costituisce l'anomalia lascia appena una traccia nella mappa dell'errore. Su questa scena, ordinare i fotogrammi per errore di ricostruzione è quasi come ordinarli per quanto sono contrastati e ricchi di texture, ed è per questo che l'AUC scende sotto 50. Il motivo è quello visto nella sezione 2.3: l'errore quadratico cresce con l'ampiezza dei valori dei pixel.

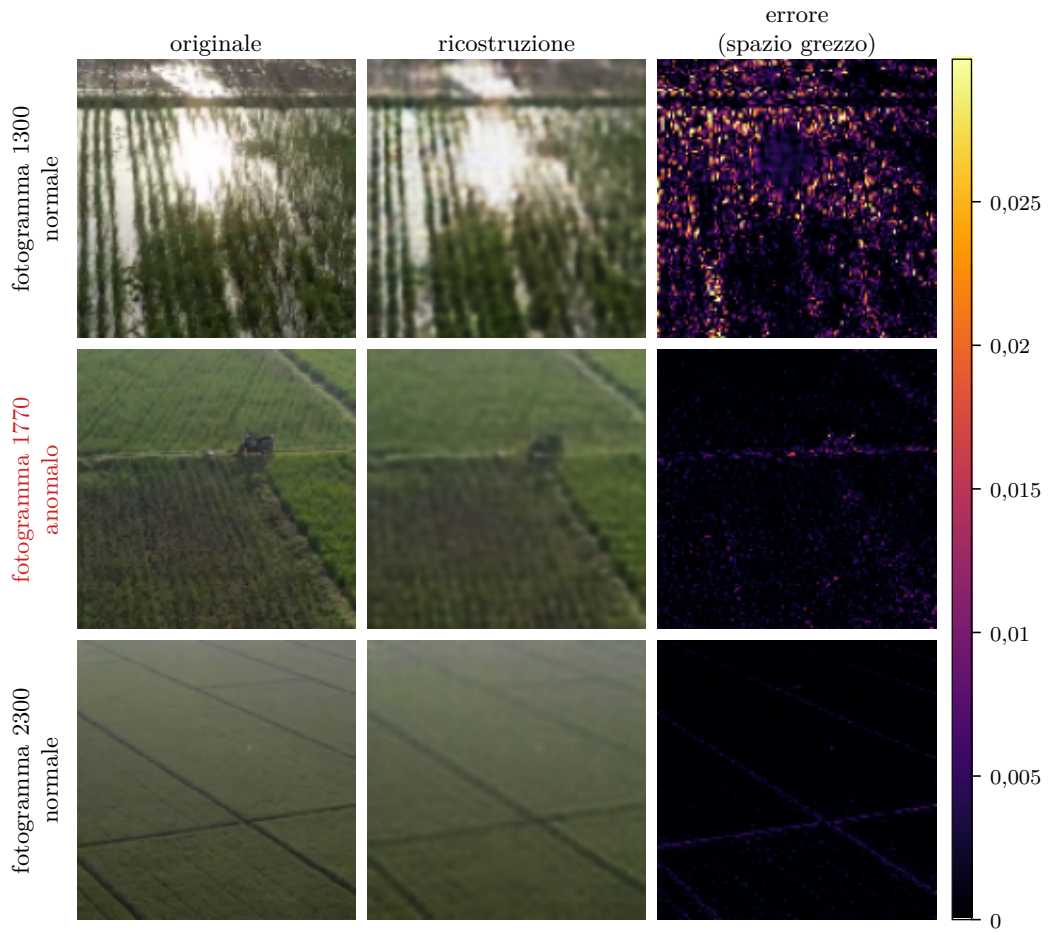


Figura 6.1. Farmland Inspection, modello 2D non corretto: fotogramma originale, ricostruzione e mappa dell'errore in spazio grezzo, per tre fotogrammi dello stesso video e con una scala di colore comune. Il fotogramma normale 1300, il più contrastato, ha l'errore più alto; il veicolo che costituisce l'anomalia, nel fotogramma 1770, nella mappa si vede appena.

La figura 6.2 mostra l'altra faccia dello stesso meccanismo. Railway Inspection è la scena su cui la correzione guadagna di più, da 54,7 a 84,9 di AUC. Eppure la mappa dell'errore del modello normalizzato non si concentra sull'anomalia: l'ostacolo chiaro accanto al binario viene ricostruito quasi com'è, e l'errore resta sulle rotaie, sia nel fotogramma anomalo sia in quello normale. Il guadagno, quindi, viene dall'aritmetica. In questo video i fotogrammi anomali sono sistematicamente meno contrastati di quelli normali, tanto che il contrasto da solo, usato come punteggio, li ordina al contrario (AUC 21,6). Dividere l'errore per σ^2 alza il punteggio dei fotogrammi meno contrastati, e quindi proprio di quelli anomali. In altre parole, la correzione non ha insegnato al modello a vedere l'ostacolo: ha tolto dal punteggio un canale che lavorava contro. Il capitolo 7 trasforma questo meccanismo in una relazione misurata su tutti i video.

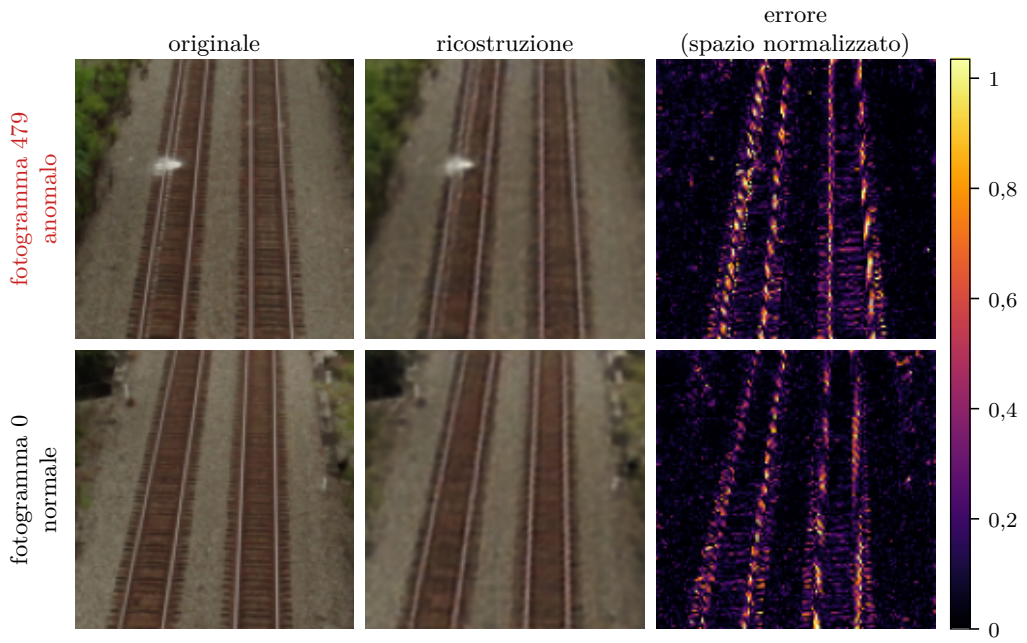


Figura 6.2. Railway Inspection, modello 2D normalizzato: un fotogramma anomalo e uno normale. L'ostacolo chiaro accanto al binario viene ricostruito quasi com'è e nella mappa non si distingue, mentre l'errore si concentra sulle rotaie in entrambi i fotogrammi.

6.2 Quale grandezza conta davvero

L'errore segue la texture, ma questo non dice ancora quale grandezza bisogna togliere. Potrebbe essere il contrasto, la texture stessa o la complessità visiva in generale. Nell'ultimo caso dividere per la deviazione standard sarebbe solo uno fra tanti rimedi possibili.

Per capire quale conta davvero, ciascuna di esse è stata usata da sola come punteggio di anomalia, video per video, e si è guardato quale predice il guadagno della correzione su quel video. Il ragionamento è semplice: se si toglie un canale, il risultato dovrebbe peggiorare dove quel canale portava segnale e migliorare dove portava solo disturbo. La grandezza giusta è quindi quella che predice il segno dell'effetto e l'ordine dei video.

Le due candidate naturali sono il contrasto e la texture. Il contrasto è la deviazione standard dei valori dei pixel del fotogramma. La texture è misurata come *energia del gradiente*, cioè la media del quadrato delle differenze fra pixel vicini: è alta dove l'immagine cambia in fretta da un pixel all'altro, e bassa sulle superfici lisce. È stata aggiunta anche la lunghezza di compressione, cioè il numero di byte che il fotogramma occupa una volta ricodificato in PNG, perché è una misura quasi pura di complessità. Un'immagine regolare, come un cielo liscio o una parete uniforme, si comprime moltissimo; una irregolare, come il fogliame o le risaie, si comprime male. La tabella 6.1 riporta il risultato.

Tabella 6.1. La specificità. Ogni grandezza è usata da sola come punteggio di anomalia; la colonna riporta la correlazione di Spearman, sui 22 video, fra la sua AUC e il guadagno prodotto dalla correzione. Un valore vicino a -1 significa che, dove la grandezza riconosce bene l'anomalia, toglierla fa danno; un valore vicino a 0 che non c'è legame.

la sola grandezza come punteggio di anomalia	ρ con il guadagno
contrasto (deviazione standard dei pixel)	$-0{,}848$
texture (energia del gradiente)	$-0{,}553$
compressione (byte PNG)	$+0{,}011$

Se il canale da togliere fosse la complessità in generale, le tre righe dovrebbero essere simili. Invece la compressione, che è quasi la definizione stessa di complessità, non ha nessun legame con l'effetto, e la texture ne ha poco più della metà del contrasto. È l'argomento contro l'ipotesi che il contrasto sia solo un indicatore indiretto della complessità, ed è il motivo per cui la relazione del capitolo 7 è formulata sul contrasto e non su una misura di texture.

Questa misura dice quale grandezza *predice* il guadagno, non quale denominatore conviene usare per la correzione.

6.3 Lo spazio di misura contro il modello

Il confronto fra le varianti della tabella 5.1 cambia però due cose insieme: il *modello*, che viene riaddestrato nello spazio normalizzato, e lo *spazio* in cui si misura il suo errore. Per capire quale delle due conta, sono state separate.

Separarle non richiede nuovi addestramenti. Per l'equazione (5.1), passare da uno spazio all'altro significa dividere per σ^2, quindi l'errore di ciascun modello si può esprimere in entrambi gli spazi. Il risultato è la tabella 6.2.

Tabella 6.2. I quattro incroci fra il modello addestrato e lo spazio in cui si misura il suo errore. I valori si raggruppano per spazio di misura, non per modello.

modello addestrato	errore misurato in	Micro per-scena	Macro per-scena
senza z-score	spazio grezzo	58,4	53,9
senza z-score	spazio normalizzato	64,5	62,7
con z-score	spazio normalizzato	65,3	62,8
con z-score	spazio grezzo	58,0	53,8

A modello fisso, cambiare spazio sposta la Micro per-scena di $+6{,}1$ e $-7{,}3$ punti. A spazio fisso, cambiare modello la sposta di $-0{,}4$ e $+0{,}8$, e la Macro per-scena di meno di un decimo di punto. Il modello addestrato con lo z-score, se misurato nello spazio originale, torna quasi dove sta quello addestrato senza (58,0 contro 58,4).

Quindi l'ingrediente decisivo è lo spazio in cui si misura l'errore, non il modello. La conseguenza pratica è che quasi tutto il guadagno si ottiene senza riaddestrare nulla.

Per leggere bene la tabella servono tre precisazioni. La riga "con z-score, spazio grezzo" si ottiene moltiplicando per σ^2 l'errore di quello stesso modello: esprime il

suo errore in un'altra unità, mentre un modello addestrato davvero con l'obiettivo grezzo imparerebbe pesi diversi. La combinazione "input normalizzato, obiettivo grezzo" invece non ha senso, perché a partire da $z(x)$ il decoder non può ricostruire x senza conoscere μ e σ. Infine, il fatto che le due righe normalizzate siano vicine in media non vuol dire che lo siano su ogni video, come mostra la sezione seguente.

6.4 Equivalenti in media, non intercambiabili per video

Sui valori medi le due forme della correzione distano frazioni di punto: 65,3 contro 64,5 in Micro per-scena, 62,8 contro 62,7 in Macro per-scena. Video per video, invece, la distanza fra le due AUC ha una mediana di 3,0 punti e un massimo di 13,8. Su un video di Crossroads lo z-score sul punteggio è avanti di 13,8 punti, su uno di Vehicle Roundabout è indietro di 7,8.

Non si riesce nemmeno a prevedere quale delle due conviene su un dato video. La correlazione di Spearman fra AUC_σ, la grandezza che nel capitolo 7 predice il guadagno, e la differenza fra le due forme vale +0,012.

Visto che non c'è una regola, la scelta si fa in base ai vincoli pratici. Da questo punto di vista lo z-score sul punteggio è preferibile: non richiede di riaddestrare, e si applica all'errore di un modello che esiste già con il costo di una divisione per fotogramma.

6.5 I limiti della correzione

La correzione attenua il confound, ma non lo elimina del tutto, come mostra la figura 6.3 su Farmland.

Inoltre la correzione introduce un problema nuovo, sui fotogrammi quasi uniformi. Un fotogramma è quasi uniforme quando i suoi pixel hanno quasi tutti lo stesso valore, per esempio quando l'inquadratura è occupata quasi per intero da un campo o da una superficie omogenea. In questi fotogrammi il contrasto σ è molto piccolo, e le poche variazioni che restano non sono struttura dell'immagine, ma rumore del sensore e artefatti della compressione. Lo z-score sull'input divide ogni pixel per σ, quindi una σ molto piccola ingrandisce proprio questo rumore, fino a dargli la stessa ampiezza che ha la struttura vera in un fotogramma normale. Il modello non lo sa ricostruire, perché nel rumore non c'è niente di regolare da imparare, e l'errore sale. Con lo z-score sul punteggio succede la stessa cosa per via aritmetica: l'errore viene diviso per σ^2, e se σ è piccola il punteggio diventa grande anche quando la ricostruzione era buona. In entrambi i casi nascono falsi positivi che il modello non corretto non aveva.

I fotogrammi più a rischio, con σ sotto 0,08, sono pochi: il 9,7 % nel video di Farmland, il 2,2 % in uno dei tre video di Solar Panel, e nessuno negli altri venti video. La tendenza però è diffusa. Al punto operativo del capitolo 9, il 58,7 % dei falsi allarmi del modello normalizzato cade su fotogrammi con σ sotto la mediana del proprio video, contro il 31,1 % del modello non corretto. Con lo z-score sul punteggio la quota è del 55,2 %. Il fatto che la forma senza addestramento abbia quasi la stessa quota conferma che il difetto viene dall'aritmetica della divisione, e non da come il modello è stato addestrato.

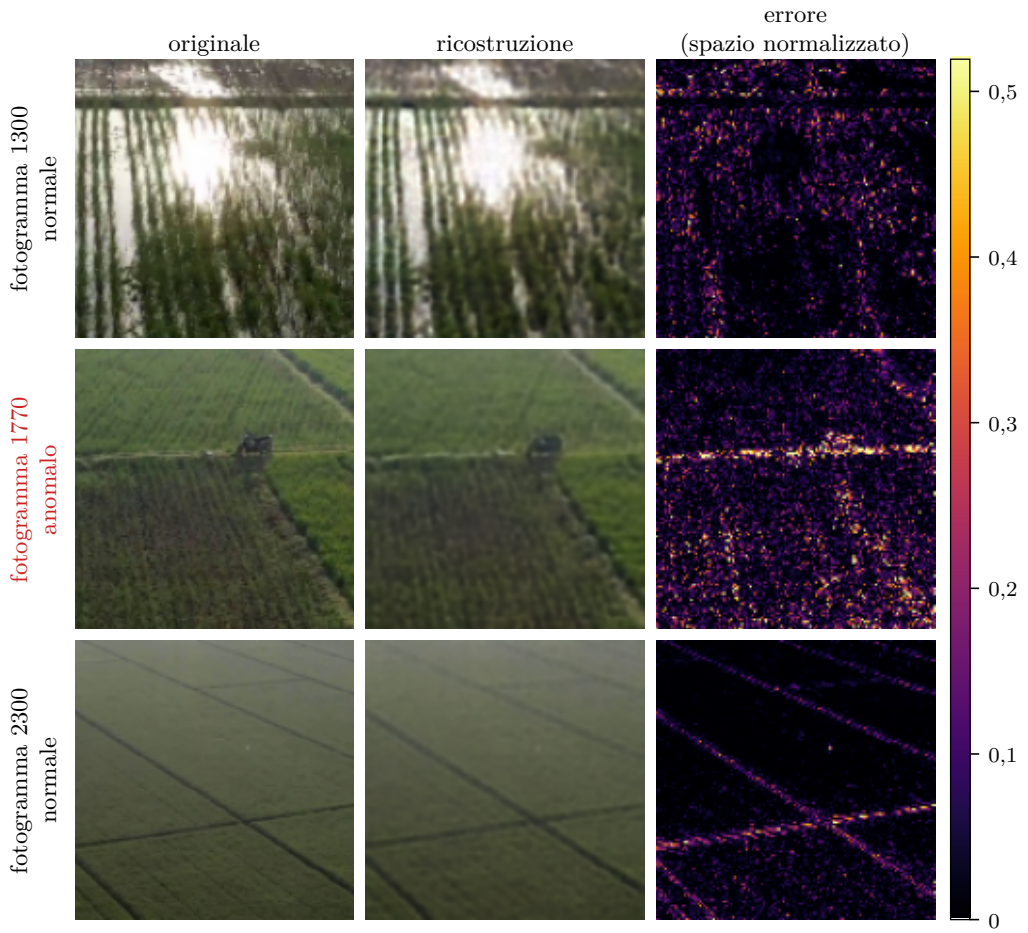


Figura 6.3. Gli stessi tre fotogrammi della figura 6.1, ricostruiti dal modello 2D normalizzato, con la mappa dell'errore nello spazio normalizzato. Il fotogramma anomalo 1770 ora ha un errore più alto del normale 1300, ma l'errore non si concentra sul veicolo: si distribuisce lungo il sentiero e i bordi dei campi. Le scale di colore delle due figure sono diverse, perché lo sono gli spazi di misura.

Un'idea per limitare il difetto è impedire a σ di scendere sotto una soglia minima. La soglia va però scelta in modo da non togliere il segnale dove il basso contrasto è proprio il segno dell'anomalia. Trovare una soluzione che funzioni in tutti i casi è uno degli sviluppi futuri (sezione 11.3).

Capitolo 7

Il trade-off del contrasto

Il capitolo precedente ha mostrato che l'errore di ricostruzione segue il contrasto e che toglierlo è un'operazione aritmetica. Resta la domanda che rende il risultato utile in pratica: quando conviene toglierlo, e quando no?

7.1 AUC_σ e la decorrelazione

La relazione si basa su una grandezza semplice. Come punteggio di anomalia si usa la sola deviazione standard dei pixel di ogni fotogramma, senza nessun modello e senza addestramento. In pratica si ordinano i fotogrammi per contrasto, e si guarda quanto bene questo ordinamento separa gli anomali dai normali. L'AUC che ne risulta, calcolata video per video, è chiamata AUC_σ.

Sui 22 video di test AUC_σ va da 12,6 a 96,7. È un intervallo molto ampio, e già questo dice molto: in questo dominio il contrasto da solo è a volte un rilevatore quasi perfetto, e a volte un rilevatore fortemente rovesciato.

La figura 7.1 mostra che cosa significa dentro due video, uno per ciascun estremo. Su Railway gli anomali sono i fotogrammi meno contrastati, e la correzione li porta da metà nuvola alla cima, come visto nella sezione 6.1. Su uno dei video di Highway succede il contrario. Gli anomali sono più contrastati della maggior parte dei normali, e la correzione alza i normali meno contrastati fino al loro livello. A decidere se la correzione aiuta o danneggia è quindi la posizione degli anomali lungo l'asse del contrasto, cioè proprio ciò che AUC_σ misura.

La prova più diretta del meccanismo è la decorrelazione. Confrontando sui 22 video AUC_σ con l'AUC dei due modelli 2D si ottiene:

	ρ con AUC_σ
AUC del modello non corretto	+0,630
AUC del modello con z-score sull'input	+0,089

Il modello non corretto segue il rilevatore basato sul contrasto, quello corretto non lo segue più. È il meccanismo del capitolo 6: la correzione non migliora il punteggio in modo generico, ma gli toglie proprio quel canale.

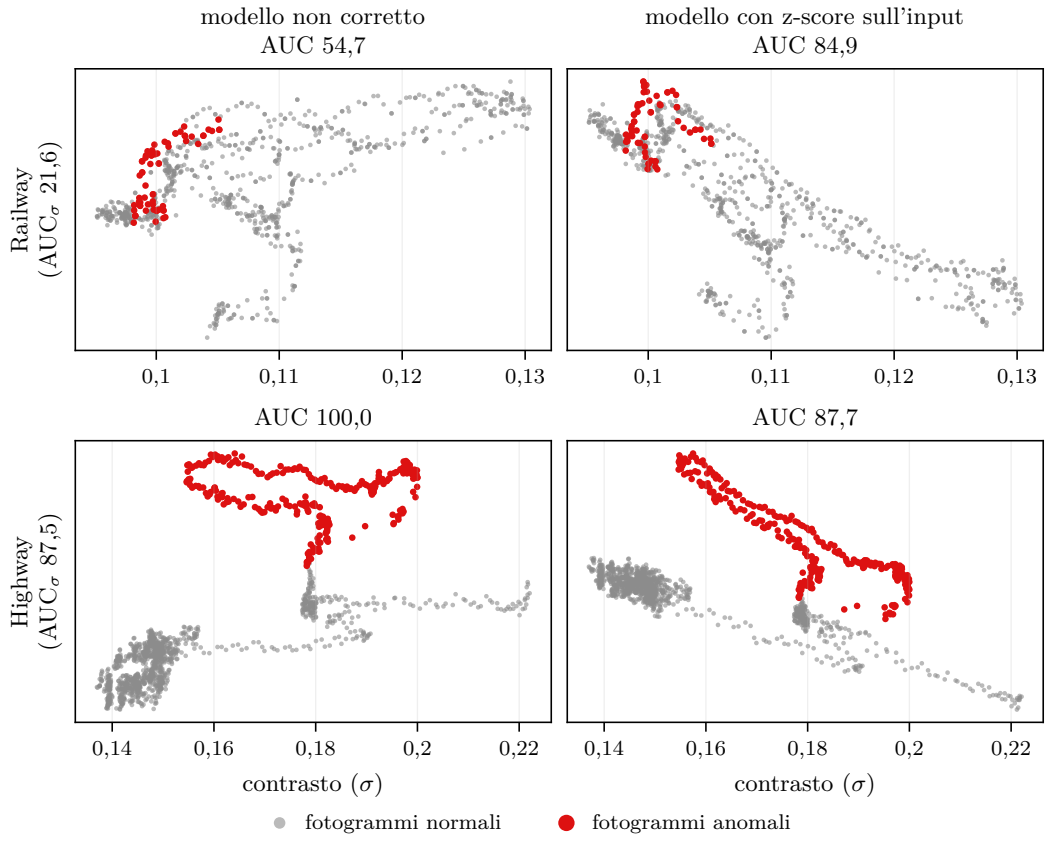


Figura 7.1. La correzione fotogramma per fotogramma, su due video agli estremi della relazione. In ascissa il contrasto di ciascun fotogramma, in ordinata il punteggio in scala logaritmica: a sinistra quello del modello 2D non corretto, a destra quello del modello con lo z-score sull'input. Sopra ogni pannello c'è l'AUC del punteggio, accanto al nome del video l'AUC$_\sigma$.

7.2 La relazione vale in entrambe le direzioni

I 22 video sono stati divisi in base ad AUC$_\sigma$, tenendo presente che 50 è il valore nullo dell'AUC. A 50 il contrasto non distingue per niente gli anomali dai normali, quindi non c'è motivo di aspettarsi un effetto. Dieci video stanno sotto 40, sette sopra 70 e cinque nel mezzo. La tabella 7.1 riporta che cosa succede nelle due zone estreme, e la figura 7.2 mostra tutti i video uno per uno.

Tabella 7.1. Le due zone della relazione. Dove il contrasto è solo disturbo toglierlo aiuta; dove è il segnale toglierlo danneggia, e lì non ci sono eccezioni. Δ è la differenza di AUC fra il modello corretto e quello non corretto.

	z-score sul punteggio		z-score sull'input	
zona	migliorano	Δ medio	migliorano	Δ medio
AUC$_\sigma < 40$ (10 video)	9/10	+21,1	9/10	+19,3
AUC$_\sigma > 70$ (7 video)	0/7	−9,1	0/7	−10,2

Sopra 70 la correzione danneggia sette volte su sette: su questi dati non è una tendenza, ma una regola senza eccezioni. Sotto 40 migliora nove volte su dieci. Quindi la relazione non prevede solo il danno, ma anche il guadagno: funziona in entrambe le direzioni.

Le due soglie non sono simmetriche rispetto a 50, e non sono state scelte con un criterio formale. Per questo si è controllato se i conteggi dipendono da questa scelta, e non dipendono: con soglie simmetriche restano altrettanto netti. Si ottiene 9/10 e 9/9 con 40 e 60, 8/8 e 9/9 con 35 e 65, 7/7 e 7/7 con 30 e 70. Anche tagliando semplicemente a 50, sotto quel valore migliorano 9 video su 11 e sopra peggiorano 10 su 11.

Le due colonne della tabella vanno lette separatamente. Quella dello z-score sul punteggio misura la sola correzione aritmetica, in cui l'addestramento non entra; quella dello z-score sull'input include anche l'effetto del riaddestramento.

La relazione è statisticamente significativa: una correlazione così forte fra AUC_σ e Δ nascerebbe per caso meno di una volta su un milione. Non è nemmeno un effetto della definizione di Δ, che contiene l'AUC del modello non corretto, già legata ad AUC_σ: anche togliendo a entrambe le grandezze la parte spiegata da quell'AUC, la correlazione resta forte, $-0{,}742$ con lo z-score sull'input e $-0{,}841$ con lo z-score sul punteggio.

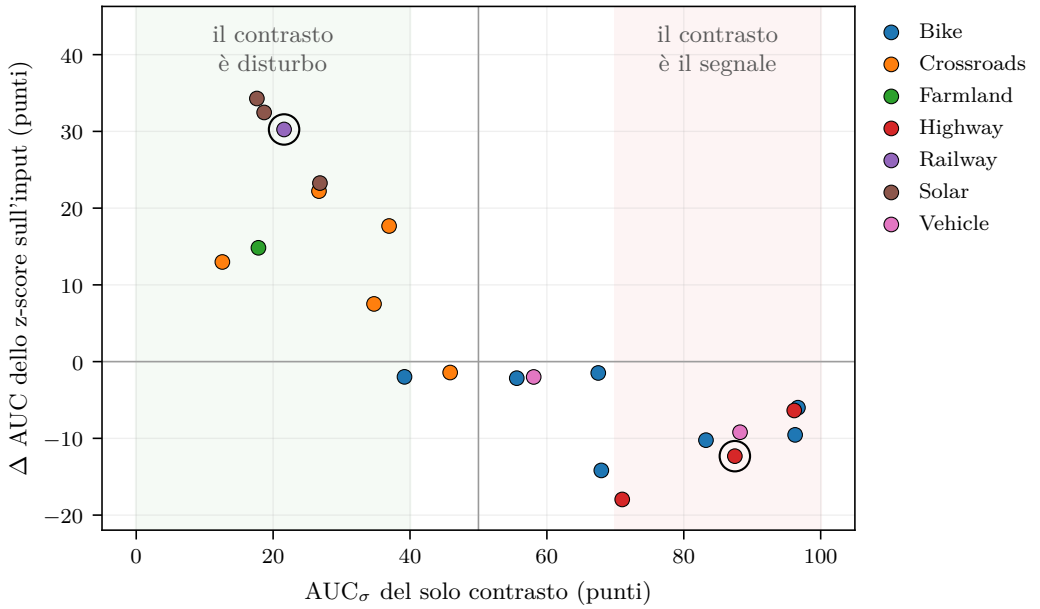


Figura 7.2. La relazione di trade-off: per ciascuno dei 22 video, l'AUC del solo contrasto in ascissa e il guadagno prodotto dallo z-score sull'input in ordinata. I punti scendono da sinistra a destra: a sinistra la correzione guadagna, a destra fa danno, ed è questo che rende possibile la previsione. I due punti cerchiati sono i video della figura 7.1.

7.3 Quando si può usare la relazione

Il contrasto si calcola dai soli pixel, senza bisogno di nient'altro. La sua AUC invece no: essendo un'AUC, ha bisogno delle etichette di quel video, per sapere

quali fotogrammi sono anomali. Per lo stesso motivo non si può stimare dai dati di addestramento, che contengono solo fotogrammi normali e non permettono di calcolare un'AUC.

La relazione quindi non permette di sapere in anticipo, senza nessuna etichetta, se la correzione conviene. Permette invece di sapere dove la correzione peggiorerà il risultato, una volta che una parte dei dati è stata annotata. In pratica potrebbe bastare annotare una ripresa per decidere sulle altre riprese della stessa scena, se il contrasto si comporta in modo simile; verificarlo è uno degli sviluppi (sezione 11.3).

La tabella 7.2 riassume che cosa si può prevedere, a quale livello, e se per farlo serve un'etichetta.

Tabella 7.2. Che cosa si può prevedere, a quale livello, e se per farlo serve un'etichetta.

livello	che cosa dice	serve un'etichetta?
dominio	quanto varia il contrasto fra i fotogrammi dice se c'è qualcosa da correggere	no
video, lato danno	AUC_σ predice il segno e l'ordinamento del danno (7/7 sopra 70)	sì
video, lato guadagno	prevedibile su Drone-Anomaly (9/10 sotto 40), non su UCSD Ped2 (capitolo 10)	sì
entità dell'effetto	di quanti punti cambia l'AUC: non è prevista, né per il danno né per il guadagno	—

Un'asimmetria. Il danno è aritmetico: dividere per σ^2 toglie il canale del contrasto in modo deterministico, qualunque sia il modello, e dove quel canale era il segnale il risultato peggiora. Il guadagno invece richiede che sotto il confound ci sia davvero un segnale da far emergere, e questo dipende dal modello e da come è stato addestrato. In pratica, quindi, è più affidabile *escludere* la correzione dove sarebbe dannosa che *garantirne* il beneficio dove dovrebbe aiutare.

Capitolo 8

Risultati su Drone-Anomaly

8.1 Il guadagno della normalizzazione

Sul protocollo di riferimento, la Micro per-scena, la normalizzazione porta il modello 2D da 58,4 a 65,3; sulla metrica di controllo, la Macro per-scena, da 53,9 a 62,8. Con un solo modello per tutte le sette scene, il risultato supera il 62,5 dell'autoencoder convoluzionale del benchmark di ANDT (sezione 8.5).

Quanto vale questo guadagno, però, dipende da come lo si misura. La tabella 8.1 riporta lo stesso confronto sui sette protocolli della tabella 2.1. Qui e nel resto della tesi le differenze sono calcolate sui valori non arrotondati, quindi possono scostarsi di un decimale dalla differenza dei valori riportati.

Tabella 8.1. Il guadagno dello z-score sull'input sui sette protocolli di misura. Gli stessi punteggi, aggregati in modi diversi, danno un effetto che va da +8,9 a −11,1. L'unico valore negativo è quello della Micro dataset, che non è usata nei confronti (sezione 2.4).

protocollo	senza z → con z	Δ
Macro per-scena	53,9 → 62,8	+8,9
Micro per-scena +minmax	58,1 → 66,4	+8,2
Micro per-scena	58,4 → 65,3	+6,9
Macro per-video	58,1 → 62,7	+4,6
Micro dataset +minmax	68,5 → 69,2	+0,7
Micro dataset +minmax (PSNR)	64,8 → 65,2	+0,4
Micro dataset	61,8 → 50,7	−11,1

L'effetto è grande sulle metriche bilanciate per scena, moderato sulla Macro per-video, quasi nullo sulle metriche di FTDMamba, e negativo solo sulla Micro dataset senza riscalatura. Quest'ultimo caso ha una spiegazione precisa. Quando tutti i video entrano in un'unica graduatoria, il modello non corretto ha un vantaggio casuale: i video con più anomalie sono anche, per caso, quelli con i punteggi su scala più alta. La normalizzazione rende omogenee le scale fra i video, e quel vantaggio sparisce.

In una fase precedente del lavoro il confronto è stato ripetuto con quattro seed diversi: la conclusione non cambia, e la variabilità dovuta al solo seed è di circa 1,7 punti sulla media per scena.

8.2 Sei normalizzazioni a confronto

Lo z-score non è ovviamente l'unico modo di normalizzare. Per questo sono state confrontate sei normalizzazioni, tutte sulla stessa architettura e con lo stesso errore quadratico come punteggio. Sono divise in tre gruppi: normalizzare l'input prima della rete, normalizzare dentro la rete, oppure correggere il punteggio dopo. La tabella 8.2 le riporta insieme al riferimento.

Tabella 8.2. Sei normalizzazioni e il riferimento, divise per gruppo.

gruppo	variante	Micro per-scena	Macro per-scena
riferimento	errore grezzo	58,4	53,9
input	z-score per fotogramma	65,3	62,8
input	sola centratura	58,9	54,4
input	min-max per fotogramma	47,5	40,5
layer	BatchNorm [3]	58,4	52,6
layer	Instance Norm [10]	54,1	48,3
punteggio	e/σ^2	64,5	62,7

La scomposizione per scena è nella tabella B.1, e mostra che la tabella non va letta come una classifica. Ogni variante toglie una statistica diversa. Lo z-score porta ogni fotogramma a media zero e deviazione standard uno, cioè allo stesso contrasto. Il min-max per fotogramma lo riscala in modo che il pixel più scuro valga 0 e il più chiaro 1, quindi toglie l'*intervallo* fra i due estremi. Non va confuso con il min-max *per video* della sezione 2.4, che agisce sul punteggio e non sull'immagine. La centratura toglie solo la media. Le due normalizzazioni dentro la rete agiscono invece sulle attivazioni interne: la BatchNorm normalizza ogni canale con media e varianza calcolate su tutto il lotto di esempi, l'Instance Norm le calcola su un'immagine alla volta. La correzione e/σ^2, infine, non tocca né l'immagine né la rete, e divide il punteggio alla fine.

Se la statistica tolta conteneva segnale, il risultato peggiora. Per questo nessuna variante vince su tutte le scene, e anche le varianti migliori in media hanno qualche AUC rovesciata.

Come leggere il confronto. Nel gruppo dell'input le tre varianti sono costruite in questa tesi. L'Instance Normalization, la variante pubblicata più vicina, è pensata dai suoi autori per i layer interni della rete, ed è lì che la si misura. Drone-Anomaly inoltre non prevede un insieme di validazione, quindi tutte le varianti sono confrontate sull'insieme di test. La correzione e/σ^2 però non ha parametri da scegliere: l'esponente di σ non è un'opzione, ma segue dalla derivazione della sezione 5.3.

8.3 2D contro 3D

Nella pianificazione iniziale il modello principale doveva essere il 3D, perché lavora su clip e vede il movimento. Il 2D a fotogramma singolo doveva servire solo a controllare che la pipeline fosse corretta prima di passare al modello più complesso. Dai risultati è emerso che su questo dominio il 2D funziona meglio, e questa sezione spiega in che senso e con quali eccezioni.

Le due architetture. Come visto nella sezione 2.2, i due colli hanno la stessa capacità per fotogramma, quindi nessuno dei due modelli ha più spazio dell'altro per trattenere l'informazione. Il confronto però non isola del tutto la dimensione temporale, perché le due reti differiscono anche nella profondità spaziale: il 3D si ferma a un collo di 16×16 pixel, il 2D scende fino a 8×8.

Senza normalizzazione. La tabella 8.3 mostra da dove viene il divario medio di dieci punti: quasi tutto da due scene, Solar Panel (−45,0) e Railway (−19,0). Sulle altre cinque la distanza non supera gli otto punti e mezzo, e su tre di esse, Crossroads, Farmland e Highway, il 3D è alla pari o avanti.

Tabella 8.3. Le due architetture scena per scena, in Micro per-scena, con e senza normalizzazione. Sulla media le versioni normalizzate quasi coincidono; scena per scena divergono fino a trenta punti, e in entrambe le direzioni.

	senza z			con z		
scena	2D	3D	Δ	2D	3D	Δ
Bike	71,5	66,5	−5,0	66,5	64,1	−2,3
Crossroads	45,5	49,5	+4,0	49,8	60,0	+10,2
Farmland	29,8	29,9	+0,1	44,6	70,0	+25,4
Highway	67,0	70,6	+3,6	61,7	64,1	+2,4
Railway	54,7	35,7	−19,0	84,9	54,4	−30,5
Solar	75,2	30,2	−45,0	85,5	81,5	−4,0
Vehicle	65,4	57,0	−8,4	64,1	60,4	−3,7
media	58,4	48,5	−10,0	65,3	64,9	−0,4

Con normalizzazione. Il guadagno è di +16,5 punti di Micro per-scena sul 3D contro +6,9 sul 2D, e di +11,5 contro +8,9 in Macro per-scena: il confound del contrasto sembra pesare di più sul modello che lavora su clip. Dopo la correzione le due medie in Micro per-scena quasi coincidono (64,9 contro 65,3), mentre in Macro per-scena resta una distanza di circa quattro punti (58,6 contro 62,8).

Scena per scena. Fra i due modelli normalizzati, il 3D sta 30,5 punti sotto il 2D su Railway, e 25,4 e 10,2 punti sopra su Farmland e Crossroads. Due medie quasi uguali nascondono quindi due modelli che sbagliano in posti diversi.

Il tipo di anomalia. Le differenze scena per scena seguono in buona parte il tipo di anomalia. Nelle scene di traffico sono soprattutto anomalie di movimento: veicoli contromano e traffico congestionato su Crossroads, collisioni e animali sulla carreggiata su Highway. Nelle ispezioni sono soprattutto anomalie di aspetto: ostacoli sui binari su Railway, oggetti estranei e pannelli difettosi su Solar Panel, veicoli non identificati su Farmland [4]. Il 3D è avanti proprio su Crossroads e Highway, con e senza normalizzazione, e resta indietro su Railway e Solar Panel, dove l'anomalia si vede già in un solo fotogramma. Bike Roundabout e Vehicle Roundabout stanno fra i due tipi. Lì l'anomalia è un veicolo nella rotatoria riservata alle biciclette, o una persona che attraversa la strada: qualcosa che si muove, ma che si riconosce già dalla sua presenza in un singolo fotogramma. Su entrambe il 2D è avanti. L'unica eccezione è Farmland, dove l'anomalia è di aspetto ma il 3D normalizzato va molto meglio, per il motivo discusso qui sotto.

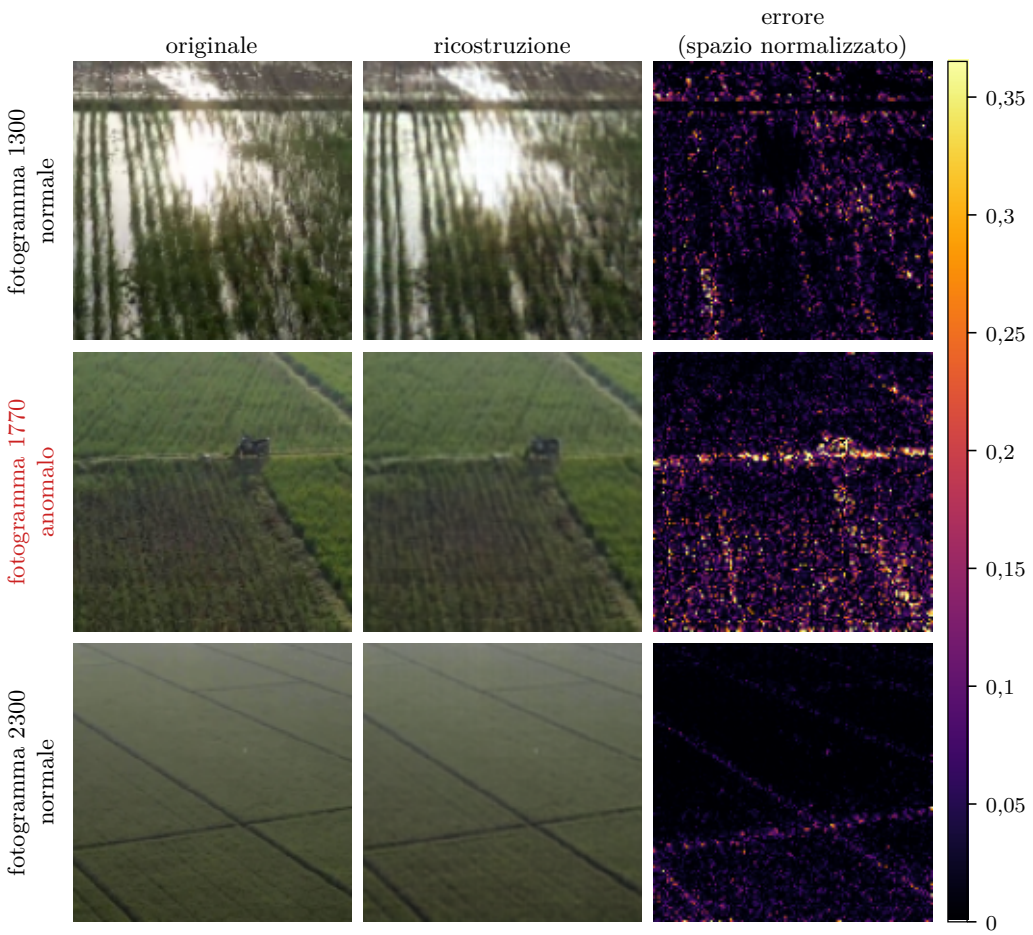


Figura 8.1. Gli stessi tre fotogrammi di Farmland delle figure 6.1 e 6.3, ricostruiti dal modello 3D normalizzato. Qui il fotogramma anomalo è il più acceso dei tre, e l'errore, oltre che lungo il sentiero, si addensa sul veicolo. La scala di colore è diversa da quella della figura 6.3, quindi il confronto affidabile è dentro ciascuna figura, non fra le due.

Farmland. È il risultato più interessante della tabella. Sulla scena che il capitolo 6 usa come esempio del confound, il 2D normalizzato arriva a 44,6 e il 3D normalizzato a 70,0. È il valore più alto ottenuto su quella scena da un modello di questa tesi.

Con il 3D (figura 8.1) il fotogramma anomalo 1770 ha un punteggio più alto del 77 % dei fotogrammi normali del video, contro il 63 % del 2D normalizzato. Inoltre, sul fotogramma normale con le linee dei campi l'errore resta basso. Un modello che ricostruisce una clip impara a riprodurre bene ciò che resta uguale da un fotogramma all'altro, come la texture del terreno, e fa più fatica con ciò che cambia. Approfondire questo meccanismo è uno dei possibili sviluppi futuri (sezione 11.3).

Su Drone-Anomaly, quindi, il 3D resta sotto il 2D su quattro scene su sette. Il motivo è lo stesso di Farmland, visto dall'altra parte: l'errore del 3D si concentra su ciò che cambia da un fotogramma all'altro. Spesso però a cambiare sono cose normali, come la posizione della camera, che si muove in una parte consistente delle riprese (sezione 3.2). Quando l'anomalia si vede già in un solo fotogramma, questo errore in più non porta informazione e copre in parte quello dell'anomalia: il tempo, invece di aggiungere segnale, lo diluisce. Su un dominio a camera fissa, dove le anomalie sono oggetti che si muovono in modo diverso dal normale, è invece il 3D a fare meglio (capitolo 10).

8.4 L'effetto di un addestramento più lungo

La ricetta della sezione 5.1 si ferma a cinque epoche. Un'obiezione naturale è che con un addestramento più lungo il modello impari da solo a ignorare il contrasto. Per controllarlo la coppia 2D è stata ripetuta con un addestramento otto volte più lungo, fino a 40 epoche. È l'unico esperimento della tesi eseguito su CUDA.

Con più addestramento il guadagno della correzione cresce, da +7,4 a +12,6 (tabella 8.4). La crescita non dipende da una sola scena, perché anche escludendo Railway il guadagno passa da +4,6 a +9,5. Non dipende nemmeno dal modo di aggregare, perché cresce anche in Macro per-video, da +4,1 a +6,7.

Tabella 8.4. Il guadagno della correzione su Drone-Anomaly al crescere dell'addestramento. Esecuzioni su CUDA.

epoche	5	20	40
Δ (con z − senza z), Micro per-scena	+7,4	+10,6	+12,6

8.5 Il confronto con lo stato dell'arte

Il confronto è organizzato in blocchi, e in ogni blocco si usa il protocollo dichiarato dal lavoro corrispondente (tabella 8.5).

La versione scena per scena, con tutti i blocchi, è nella tabella B.3.

Tabella 8.5. Il confronto, blocco per blocco. La colonna "riferimento" riporta i valori pubblicati dai rispettivi lavori [4, 6, 7], ricavati dalle loro tabelle.

blocco	protocollo	senza z	z input	z punt.	riferimento
A	HSTforU — Micro per-scena +minmax	58,1	66,4	66,7	67,0
B	FTDMamba — Micro dataset +minmax	68,5	69,2	69,8	71,6
B	FTDMamba — Macro per-video	58,1	62,7	64,2	72,3
C	ANDT — Micro per-scena, 13 modelli per sequenza	63,0	67,9	68,2	CAE 62,5 ANDT 68,6
C-bis	ANDT — Micro per-scena, 1 modello globale	58,4	65,3	64,5	

A parità di protocollo, la distanza fra l'autoencoder di questa tesi e i modelli dei tre lavori è piccola su due protocolli su quattro. Eppure quei modelli sono molto più grandi, basati su Transformer e Mamba, e predicono il fotogramma successivo invece di ricostruire quello corrente.

Con HSTforU è una sostanziale parità. Il modello globale con la correzione sul punteggio, senza riaddestramento, arriva a 66,7 contro 67,0. Il loro 67,0, inoltre, prende per ogni scena la migliore di tre configurazioni del loro modello: con la sola migliore la media è 66,6 [6]. Scena per scena i due profili sono complementari (tabella B.3). Con FTDMamba la distanza dipende dalla metrica: 69,8 contro 71,6 sulla Micro dataset con min-max per video, e un divario ampio sulla Macro per-video, 64,2 contro 72,3.

Con ANDT conta anche la **granularità**, cioè su quali dati si addestra un modello. Come nel codice pubblicato da ANDT, il blocco C usa tredici modelli *per sequenza*, ciascuno addestrato su una delle tredici sequenze e valutato solo sui suoi video. Con questi modelli l'autoencoder corretto arriva a 68,2 contro 68,6: una differenza di 0,4 punti, più piccola della variabilità da seed (sezione 8.1). Il blocco C-bis usa invece un solo modello *globale* per tutte le scene, che è il modello principale della tesi. In un uso reale, infatti, un modello per sequenza è poco realistico, perché richiede di sapere in anticipo dove volerà il drone. Anche così il modello globale supera l'autoencoder convoluzionale del benchmark di ANDT, che usa i modelli per sequenza: 65,3 contro 62,5. Specializzare i modelli vale +4,6 punti senza correzione e +2,5 con la correzione: i due interventi non si sommano, perché anche la specializzazione riduce, in modo più costoso, la varietà del normale.

Capitolo 9

Dalla metrica al compito

Tutto quello che precede è misurato in AUC, cioè in quanto bene il modello *ordina* i fotogrammi. È anche la misura su cui si concentra la letteratura, e il motivo sta proprio nella difficoltà del compito. In addestramento non ci sono anomalie, quindi non c'è un modo diretto per scegliere la soglia. Inoltre anche i metodi migliori, nel punto in cui i due errori si pareggiano, segnalano almeno un terzo dei fotogrammi normali (sezione 9.4). L'AUC invece confronta i metodi senza doverne scegliere una. Dei tre lavori del benchmark, infatti, solo ANDT pubblica anche metriche a soglia. HSTforU riporta soltanto l'AUC, e FTDMamba l'AUC e l'EER, che è un punto della curva ROC e non una soglia scelta.

Questo capitolo risponde a una domanda diversa, più vicina all'uso: come si passa dal punteggio a una decisione, e con quale prestazione?

9.1 Dall'ordinamento alla decisione

L'AUC misura una graduatoria, ma a chi sorveglia una graduatoria non basta: vuole sapere se un'anomalia è stata notata. Che lo siano stati tutti i suoi fotogrammi conta molto meno, perché un evento segnalato anche solo in parte porta comunque un operatore a guardare quel punto del filmato.

L'unità di misura del capitolo è quindi l'**evento**, cioè un intervallo di fotogrammi anomali consecutivi; i 22 video di test ne contengono 26. Un evento è **rilevato** se almeno un fotogramma d'allarme cade al suo interno, e un **falso allarme** è un tratto d'allarme che non tocca nessun evento.

Per passare dal punteggio continuo a una decisione serve una soglia, e il modo in cui la si sceglie conta quanto il modello. Sono stati confrontati due regimi, che rispondono a domande diverse e hanno limiti diversi.

- *A priori.* La soglia si stima dagli errori di ricostruzione sull'insieme di addestramento, che è tutto normale: è la loro media più una deviazione standard. È lo stesso criterio che ANDT usa per le sue metriche a soglia [4]. Si può usare fin dal primo fotogramma, perché non serve aver visto il video da giudicare.
- *A posteriori, non supervisionato.* La **soglia di Otsu** [9] si calcola sulla distribuzione dei punteggi del video di test, mai sulle sue etichette. Fra tutti i tagli possibili sceglie quello che separa meglio le due parti, cioè quello che

massimizza la varianza *fra* i due gruppi. È un criterio nato per binarizzare immagini in scala di grigi, che qui si applica alla curva dei punteggi. Richiede di aver visto l'intero video, ma per costruzione assorbe lo scostamento fra addestramento e test.

9.2 Il regime a priori

Su Drone-Anomaly la soglia a priori ha due problemi, opposti fra loro. Su Farmland non intercetta nemmeno un fotogramma anomalo (recall dello 0 %), mentre su Railway segnala tutto, anomali e normali insieme (recall e tasso di falsi positivi del 100 %). Nel complesso il modello principale arriva a 60,3 di F1. La tabella B.4 riporta i valori scena per scena e rende visibili entrambi i problemi.

Il problema non sta nel metodo, ma nello scostamento fra i punteggi di addestramento e quelli di test: su Drone-Anomaly questo scostamento è forte, e una soglia fissata in addestramento non può tenerne conto. Su un dominio a camera fissa, dove lo scostamento non c'è, la stessa soglia rileva tutti gli eventi (capitolo 10).

9.2.1 Le due granularità: quella del modello e quella della soglia

La granularità del modello (su quale parte dei dati è addestrato, sezione 8.5) e quella della soglia (su quale gruppo di fotogrammi si calcola il taglio) sono due cose diverse, facili da confondere. La tabella 9.1 le separa.

Tabella 9.1. I quattro incroci fra granularità del modello e granularità della soglia, nel regime a priori. Specializzare il modello aiuta, restringere il gruppo su cui si stima la soglia no.

modello	soglia	recall	precision	F1	OA	FPR
globale	per scena	61,9	58,8	60,3	63,4	35,4
globale	per sequenza	59,3	55,3	57,3	60,2	39,1
13 per sequenza	per scena	82,5	55,4	66,3	62,3	54,3
13 per sequenza	per sequenza*	79,5	52,1	62,9	57,9	59,8

* è la configurazione di ANDT.

A modello fisso, restringere il gruppo su cui si stima la soglia costa 3,0 e 3,4 punti di F1, perché con meno fotogrammi la stima di media più deviazione standard è più rumorosa. A soglia fissa, passare a tredici modelli vale +6,0 e +5,6. Il guadagno quindi viene dalla specializzazione del modello, non da soglie più fini.

9.3 Il regime a posteriori: la catena di Otsu

Il secondo regime risponde al limite del primo: serve a correggere lo scostamento fra addestramento e test, e non è una soglia migliore in assoluto.

La catena adottata ha tre passi, mostrati nella figura 9.1. Il primo è una **mediana mobile** su nove fotogrammi: ogni punteggio viene sostituito dalla mediana dei nove che lo circondano. In questo modo si tolgono i picchi isolati senza spostare l'inizio

e la fine dei tratti alti, cosa che invece farebbe una media. Il secondo passo è la soglia di Otsu, calcolata sulla curva lisciata del singolo video. Il terzo è una **durata minima** di otto fotogrammi: i tratti sopra soglia più brevi vengono scartati come rumore.

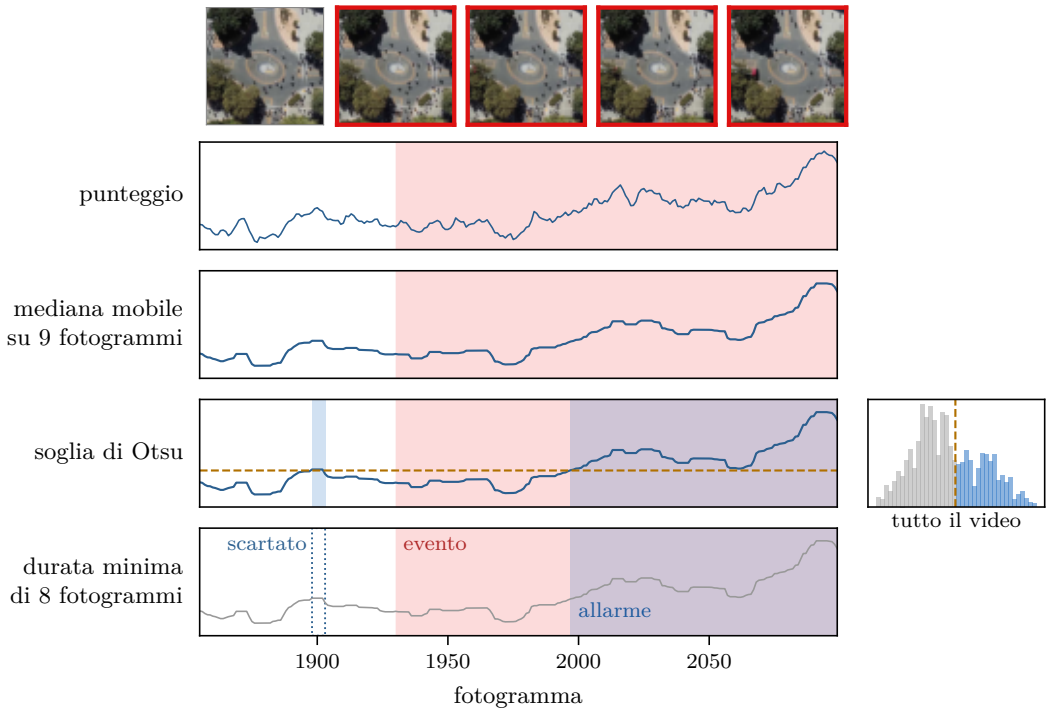


Figura 9.1. La catena passo per passo, su un tratto di un video di test di Bike Roundabout, con i punteggi del modello principale riscalati sul tratto mostrato. In cima, cinque fotogrammi del tratto, uno ogni cinquanta, con il bordo rosso dove la verità è anomala. Poi, dall'alto: il punteggio per fotogramma, la curva dopo la mediana mobile, la soglia di Otsu con i tratti che la superano, e gli allarmi che restano dopo la durata minima. A destra, l'istogramma dei punteggi lisciati di tutto il video, che il taglio di Otsu divide in due gruppi. In rosa i fotogrammi anomali, in blu i tratti sopra soglia. I tre parametri sono fissati a priori e sono gli stessi per tutte le varianti, per tutti i video e anche per Ped2: per questo il confronto fra i due domini è a parità di catena.

La figura 9.2 mostra che cosa produce la catena su quattro video, e la tabella 9.2 su tutti i ventidue.

Tabella 9.2. Rilevamento per evento. Un evento è rilevato se almeno un fotogramma d'allarme cade al suo interno.

variante	eventi rilevati	falsi allarmi / 1000 fotogrammi
2D globale, con z	22/26 — 84,6 %	1,56
2D per sequenza, con z	23/26 — 88,5 %	1,28
3D globale, con z	22/26 — 84,6 %	2,43

Gli eventi mancati. Dei quattro eventi che il modello globale non rileva, due sono proprio i casi che il resto della tesi spiega. Uno è l'evento di Farmland, la scena rovesciata dal confound (sezione 6.1). L'altro è in un video di Solar Panel, quello con il 2,2 % di fotogrammi quasi uniformi, cioè uno dei due video a rischio per il difetto della correzione (sezione 6.5).

2D e 3D. Sugli eventi i due modelli normalizzati sono alla pari: entrambi ne rilevano 22 su 26. Il 3D però lo fa con più falsi allarmi, 2,43 ogni mille fotogrammi contro 1,56. Anche sui singoli fotogrammi, contati tutti insieme, il 2D resta avanti: con il regime a priori l'F1 del 3D normalizzato è 51,0 contro 60,3, con la catena di Otsu 54,0 contro 57,6.

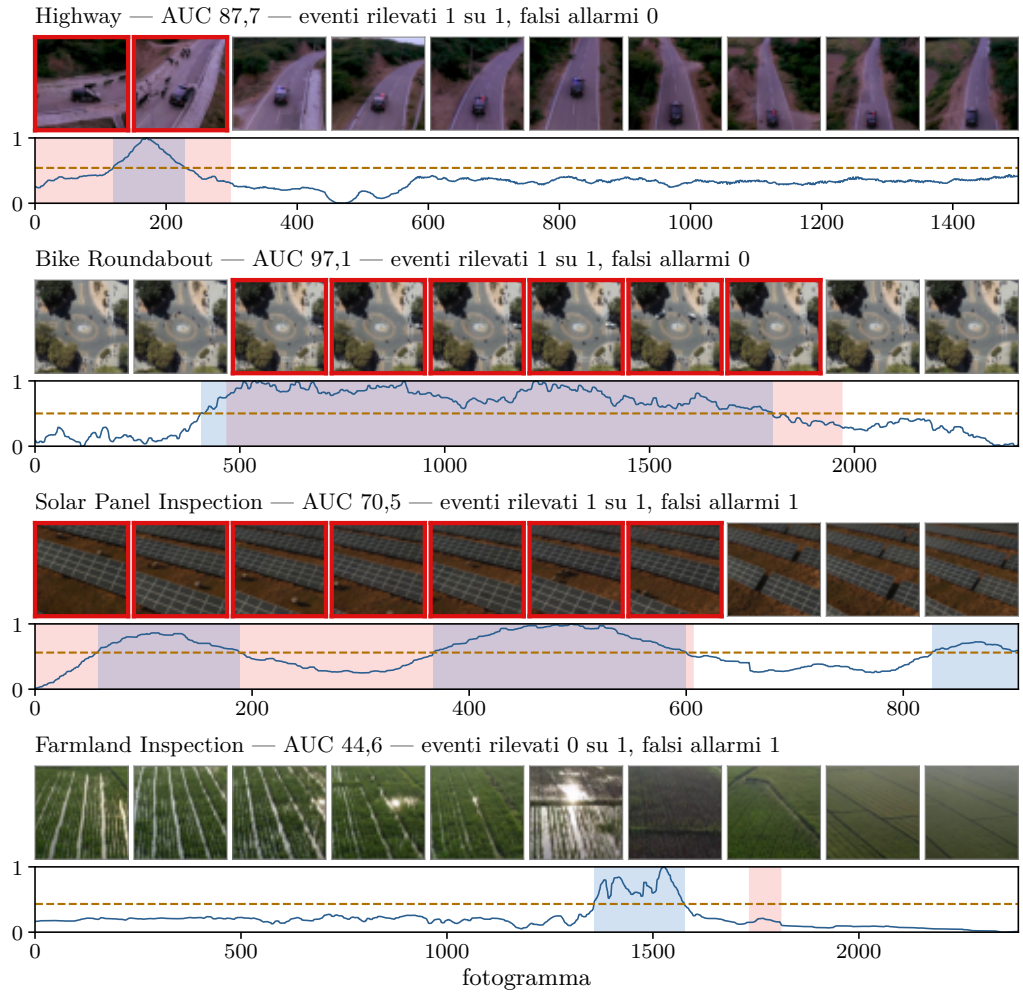


Figura 9.2. La catena all'opera. Per ciascun video: dieci fotogrammi campionati, con il bordo rosso dove la verità è anomala; il punteggio lisciato e riscalato; la soglia di Otsu tratteggiata; in blu i tratti dichiarati d'allarme. Dove blu e rosa si sovrappongono, l'evento è stato rilevato. Nei primi tre video la banda d'allarme segue bene l'evento. Il quarto è Farmland, dove allarme e anomalia non si toccano: è uno dei quattro eventi mancati della tabella 9.2, e la sezione 6.1 ne spiega il motivo.

Questi numeri dicono che, su video in cui le anomalie non sono rare, il sistema nota la grande maggioranza degli eventi con poco più di un falso allarme ogni mille fotogrammi. Non dicono invece che ridurrebbe il lavoro di revisione su ore di filmato in cui non succede quasi nulla (sezione 9.4).

Sui singoli fotogrammi conta il **punto operativo**, cioè il punto della curva ROC in cui il sistema lavora una volta fissata la soglia. È una coppia precisa di tasso di falsi positivi e recall, invece della curva intera che l'AUC riassume. Per il modello principale con la catena di Otsu, contando tutti i fotogrammi insieme, il recall è del 55,1 %, la precision del 60,3 % e il tasso di falsi positivi del 29,6 %. Per confronto, agli stessi punteggi è stata applicata una sola soglia globale, senza nessuna elaborazione. A parità di recall i falsi positivi salgono al 48,2 %: la catena, con la calibrazione per video, ne toglie quasi venti punti.

Il caso del video senza anomalie. La soglia di Otsu sceglie sempre, per costruzione, un taglio *dentro* la distribuzione dei punteggi del video. Su un video senza nessuna anomalia, quindi, segnalerebbe comunque la parte più alta. Il sistema, in altre parole, non può rispondere "non ho trovato nulla": è il prezzo della calibrazione per video. Su ore di ispezione reale questa è quasi sempre la risposta corretta, e per un uso operativo la soglia per video andrebbe affiancata da un criterio assoluto.

9.4 Il divario dall'uso reale

Il confronto con i metodi pubblicati. Un tasso di falsi positivi del 29,6 % può sembrare alto. FTDMamba però pubblica l'EER a livello di fotogramma di tredici metodi su questo benchmark, compreso il proprio [7]. Nel punto di pareggio l'EER coincide con il tasso di falsi positivi, e va dal 33,6 % di FTDMamba al 51,2 %: anche lo stato dell'arte, in quel punto, segnala un terzo dei fotogrammi normali. La valutazione per evento è quindi un buon compromesso: con il 29,6 % di falsi positivi il sistema rileva comunque 22 eventi su 26.

La distanza dall'uso reale. Rispetto ai sistemi supervisionati usati nelle applicazioni operative la distanza resta grande, e il motivo è aritmetico. Con un recall R, un tasso di falsi positivi F e una prevalenza p, la precision attesa è

$$\text{precision} = \frac{R\,p}{R\,p + F\,(1-p)}, \tag{9.1}$$

quindi, a parità di R e F, quando le anomalie diventano rare i falsi positivi prendono il sopravvento. La tabella 9.3 fa il conto con i valori del punto operativo.

Tabella 9.3. La precision attesa al variare della prevalenza, secondo l'equazione (9.1), tenendo fissi il tasso di falsi positivi al 29,6 % e il recall al 55 %.

prevalenza	precision attesa
45 % (insieme di test di Drone-Anomaly)	60 %
1 %	∼1,8 %
0,1 %	∼0,2 %

Questo limite dipende più dal compito che dal modello. Cercare un'anomalia generica senza supervisione porta a tassi di falsi positivi come quelli visti sopra, comuni a tutti i metodi pubblicati.

Capitolo 10

Verifica su UCSD Ped2

Questo capitolo ripete tutta la pipeline su UCSD Ped2, un dominio a camera fissa e molto più semplice di Drone-Anomaly (sezione 4.3). Lo scopo principale è verificare se la relazione di trade-off si trasferisce. Allo stesso tempo l'esperimento misura con la stessa pipeline il gradiente di difficoltà della figura 3.1. I risultati su Ped2 sono molto migliori, e confermano che la difficoltà di Drone-Anomaly sta soprattutto nel problema, più che nel modello.

10.1 Impostazione e risultati

Rispetto a Drone-Anomaly cambia solo il dataset, con un'eccezione: la durata dell'addestramento. Architetture, ricetta e parametri della catena decisionale sono gli stessi, senza nessuna regolazione. La durata è stata adattata con una regola fissata prima di eseguire. Ped2 ha venti volte meno fotogrammi di addestramento, quindi a parità di epoche la rete farebbe venti volte meno aggiornamenti dei pesi. Per questo è stato pareggiato il numero di *iterazioni*: 4.035 per il 2D e 10.730 per il 3D, cioè le stesse che su Drone-Anomaly corrispondono alle cinque epoche della ricetta.

La tabella 10.1 riassume i risultati, e la tabella B.2 riporta le AUC video per video. La figura 10.1 mostra i punteggi da cui questi numeri vengono. Con il min-max per video i valori sono in linea con l'83,0 che HSTforU riporta per un autoencoder a ricostruzione con layer ConvLSTM [6].

Tabella 10.1. Risultati su UCSD Ped2. Con una sola scena la Micro per-scena e la Micro dataset coincidono: la prima colonna è quindi la Micro con min-max per video, la seconda la media delle AUC degli otto video che ne hanno una. Eventi e falsi allarmi sono quelli della catena di Otsu (sezione 9.3). In senso assoluto i risultati sono molto migliori che su Drone-Anomaly, e qui è il 3D a fare meglio.

variante	Micro +minmax	Macro (8 video)	eventi	falsi allarmi
2D senza z	81,4	84,3	12/12	2
2D con z-score	83,3	83,9	12/12	0
3D senza z	82,5	86,8	12/12	1
3D con z-score	85,5	87,0	12/12	1

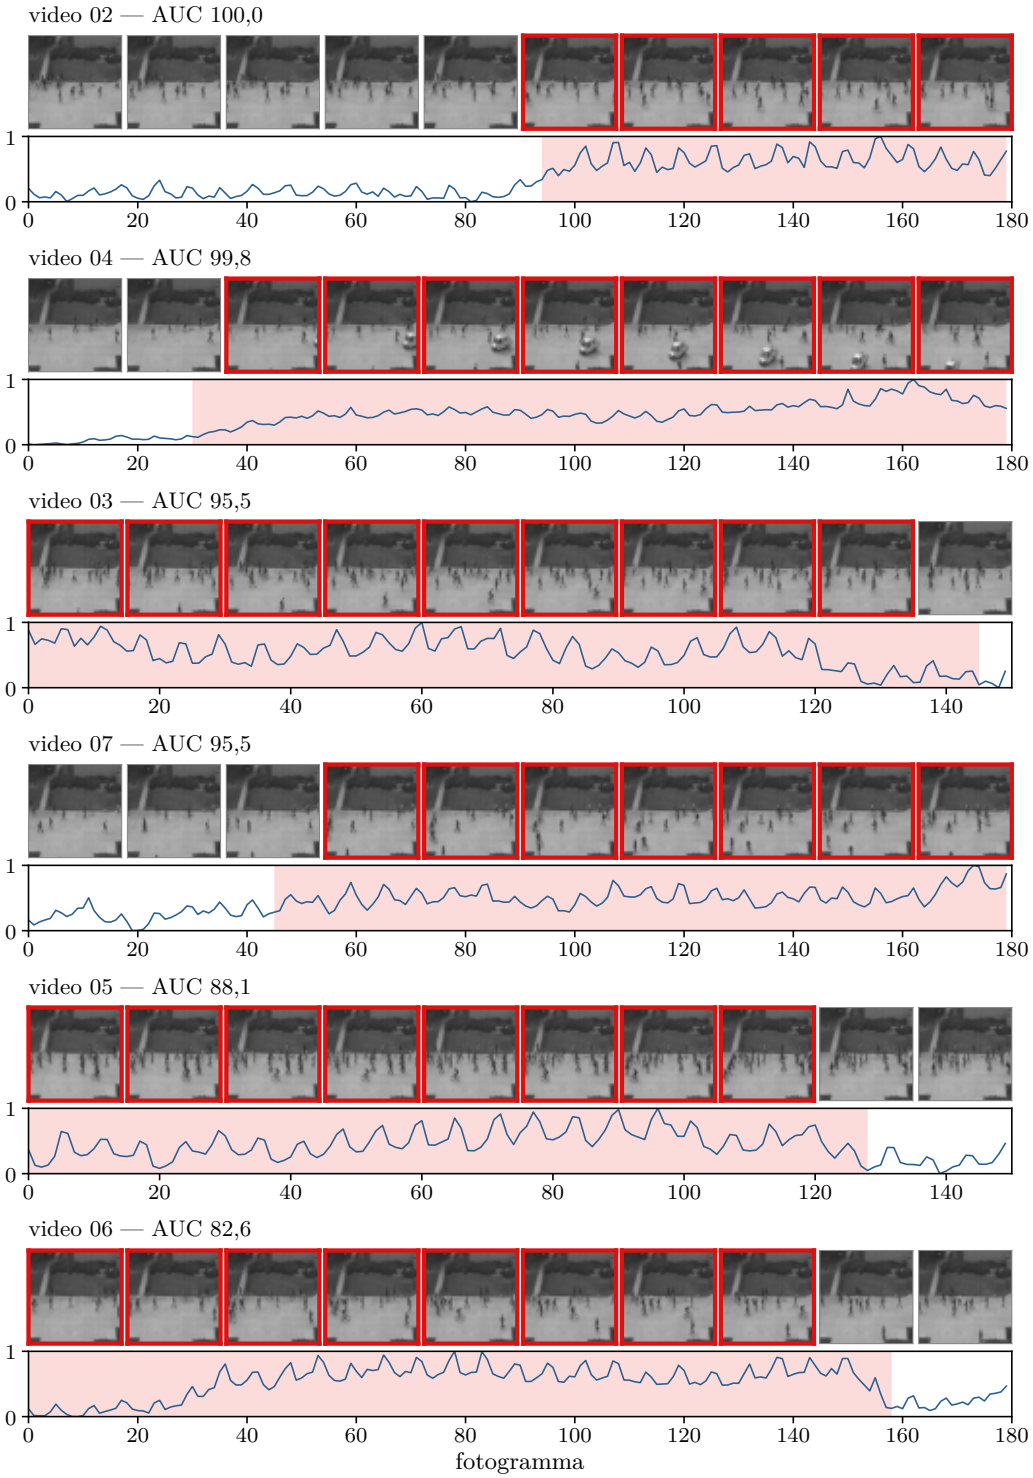


Figura 10.1. Il modello 3D con z-score sui sei video di Ped2 in cui ordina meglio, con i punteggi riscalati per video e in rosa i fotogrammi anomali. Su un dominio a camera fissa le curve salgono dentro la banda rosa e ci restano. I primi due video sono quasi al massimo, con AUC 100,0 e 99,8: dove la curva separa già perfettamente, non c'è spazio perché una correzione mostri un effetto (sezione 10.2).

10.2 La relazione fuori dominio

Verificare se la relazione si trasferisce era lo scopo principale di questo esperimento. La relazione descrive un confound che nasce quando il contrasto varia molto da un fotogramma all'altro. Su Ped2, con camera fissa e una sola scena, il contrasto varia molto meno. In una fase precedente del lavoro si è misurato che fra un fotogramma e l'altro varia 6,1 volte meno che su Drone-Anomaly. C'è quindi poco confound da togliere, e il guadagno della correzione dipende soprattutto da altro.

La tabella 10.2 riassume l'esito: come previsione del guadagno, su Ped2 la relazione non si trasferisce.

Tabella 10.2. La relazione come previsione del guadagno su Ped2. Per ciascun video il segno di Δ era stato previsto da AUC_σ prima di qualunque esecuzione; la tabella riporta quante previsioni si sono verificate e la correlazione fra AUC_σ e Δ.

coppia	previsioni verificate	$\rho(\mathrm{AUC}_\sigma, \Delta)$
coppia 2D	3/8	$+0{,}205$ $(p = 0{,}63)$
coppia 3D	4/8	$+0{,}133$ $(p = 0{,}75)$

La correlazione non è significativa, ed è di segno opposto a quella misurata su Drone-Anomaly. Il valore p, cioè la probabilità di trovare per caso una correlazione almeno così forte, è di 0,63 e 0,75: la correlazione è del tutto compatibile con il caso.

Il lato del danno. Il video 01 è l'unico di Ped2 con AUC_σ alta, 99,0, cioè l'unico in cui il contrasto è segnale e non disturbo. Per quel video la relazione prevedeva $\Delta < 0$, e la correzione fa $-2{,}9$ sul 2D e $-3{,}2$ sul 3D: la previsione è corretta su entrambe le coppie. È anche l'unico video con AUC sotto 50 nella coppia 2D (44,4 senza z, 41,5 con z). Si tratta di un solo video, quindi di una conferma debole, ma va nella direzione dell'asimmetria della sezione 7.3: la previsione del danno si trasferisce, quella del guadagno no.

Dove cadono le previsioni sbagliate. Nel 2D tre previsioni sbagliate su cinque riguardano video che partono già quasi dal massimo: 02, 04 e 07, con AUC senza correzione fra 98,7 e 100,0. Lì non c'è spazio perché la correzione mostri un guadagno, e la previsione non si poteva né confermare né smentire. Le altre due sono previsioni smentite: sul video 06 la correzione fa perdere 13,1 punti dove la relazione prevedeva un guadagno, e sul video 12 ne fa guadagnare 9,2 dove prevedeva un effetto piccolo. Sul 3D gli stessi due video danno $-3{,}7$ e $+5{,}6$.

10.3 L'effetto di un addestramento più lungo

Anche su Ped2 la quinta epoca è stata confrontata con la fine di un addestramento circa venti volte più lungo. L'effetto della normalizzazione misurato in Macro per-video si riduce: da $+4{,}5$ a $+0{,}1$ sul 3D, da $-2{,}8$ a $-0{,}4$ sul 2D. Sull'AUC con min-max per video, invece, non si riduce: il 2D passa da $-5{,}0$ a $+1{,}9$ e il 3D da

+1,6 a +3,0. Le variazioni lungo l'addestramento vanno quindi lette su più metriche, perché una sola può muoversi per ragioni di scala.

Su Drone-Anomaly, invece, con più addestramento il guadagno della correzione cresce (sezione 8.4). Una lettura coerente con entrambi i domini è questa. Dove la varietà del normale è stretta e la σ dei fotogrammi è quasi costante, come su Ped2, non c'è un confound di contrasto da togliere. Quel poco che c'è, il modello lo assorbe da solo con abbastanza addestramento. Dove il confound è forte, l'addestramento lo amplifica, e toglierlo vale sempre di più.

10.4 2D contro 3D

Su Ped2 è invece il 3D a fare meglio: 85,5 contro 83,3 con il min-max per video, 87,0 contro 83,9 in Macro (tabella 10.1). Qui la camera non si muove, lo sfondo è fermo, e le anomalie sono oggetti che si muovono in modo diverso dal normale: è proprio il caso in cui vedere il movimento serve di più.

La lettura più semplice, compatibile con entrambi i domini, è che l'informazione temporale non sia utile o inutile in generale. Serve dove l'anomalia è un movimento su uno sfondo fermo, e può costare dove a muoversi è la camera. Su Drone-Anomaly la camera si sposta in una parte consistente delle riprese, e il 3D resta sotto il 2D su quattro scene su sette (sezione 8.3). Separare le riprese con la camera in movimento da quelle con il drone fermo permetterebbe di verificarlo (sezione 11.3).

10.5 La decisione su Ped2

Anche sulla decisione binaria Ped2 conferma che la difficoltà di Drone-Anomaly sta soprattutto nel dominio.

Con il regime a priori la stessa soglia, con gli stessi parametri, rileva 12 eventi su 12 in tutte e quattro le varianti. I falsi allarmi sono 2 sul 2D e fra 17 e 19 sul 3D. Letto per fotogramma, però, il quadro è diverso: la soglia a priori segnala fra l'86 % e l'88 % dei fotogrammi normali con il 2D, e fra il 55 % e il 57 % con il 3D. Taglia molto in basso, e su un insieme di test anomalo all'82 % questo basta per avere un recall alto. Per evento la stessa decisione è eccellente, per fotogramma no.

La catena di Otsu migliora ancora i risultati: il 2D con z-score passa da 2 falsi allarmi a nessuno. Qui però non corregge nessuno scostamento fra addestramento e test, perché su Ped2 questo scostamento non c'è.

Con la catena di Otsu e gli stessi parametri, il tasso di falsi positivi è del 5,8 % con un recall del 65,5 %. Su Drone-Anomaly era del 29,6 % con un recall del 55,1 %, quindi Ped2 va meglio su entrambe le misure.

In sintesi, su Ped2 la pipeline funziona molto meglio in senso assoluto, e il modello su clip supera quello a fotogramma singolo. La previsione del danno si conferma sull'unico video in cui si poteva metterla alla prova. La previsione del guadagno invece non si trasferisce, coerentemente con il fatto che su questo dominio c'è poco confound da togliere.

Capitolo 11

Discussione, conclusioni e sviluppi futuri

11.1 Discussione

I risultati dei capitoli precedenti si capiscono meglio insieme che uno alla volta, perché hanno un'origine comune: in Drone-Anomaly la nozione di normale è molto varia. Le sette scene sono diverse fra loro, un solo modello deve coprirle tutte, e in una parte delle riprese la camera si sposta. Da qui derivano osservazioni che, prese da sole, sembrerebbero scollegate.

Il contrasto del singolo fotogramma è il canale principale attraverso cui questa varietà entra nell'errore di ricostruzione. Per questo Farmland è rovesciata: i fotogrammi normali più contrastati hanno l'errore più alto (sezione 6.1). Per lo stesso motivo Railway guadagna trenta punti senza che il modello impari a vedere l'ostacolo, perché lì i fotogrammi anomali sono meno contrastati. E lo spazio in cui si misura l'errore conta più del modello che lo produce, perché passare da uno spazio all'altro è una divisione per σ^2 (sezione 6.3).

La correzione funziona perché riduce la varietà del normale così come la vede il modello. Lo stesso fa, in modo più costoso, la specializzazione dei tredici modelli per sequenza, e infatti i due interventi non si sommano (sezione 8.5). La correzione resta però un'operazione aritmetica che toglie un canale dal punteggio, non un modo di far vedere l'anomalia al modello. Attenua il confound senza eliminarlo, e introduce un difetto nuovo sui fotogrammi quasi uniformi (sezione 6.5). Il suo valore dipende dal video, ed è la relazione del capitolo 7 a renderla utilizzabile, perché dice dove farà danno.

Anche il confronto fra le due architetture si legge così. Il modello su clip non compensa la varietà del normale: in una parte delle riprese a muoversi è la camera, e molte anomalie si vedono già in un solo fotogramma. Il 3D va meglio dove l'anomalia è un movimento, come su Crossroads e Highway, e su Ped2, a camera fissa, è il modello migliore in assoluto (sezioni 8.3 e 10.4).

Su Ped2, dove la varietà del normale è stretta e la σ dei fotogrammi è quasi costante, la stessa pipeline va molto meglio, e la correzione ha poco su cui agire. La previsione del danno si conferma sull'unico video in cui si poteva metterla alla prova, mentre quella del guadagno non si trasferisce (capitolo 10).

Infine, fra una buona graduatoria e una decisione utilizzabile c'è la soglia. Su Drone-Anomaly una soglia fissata in addestramento risente dello scostamento fra addestramento e test, che una soglia calcolata sul video da giudicare assorbe (sezioni 9.2 e 9.3). La distanza dall'uso reale dipende soprattutto dal compito così come è formulato e dalla prevalenza delle anomalie, ed è comune a tutti i metodi pubblicati (sezione 9.4).

11.2 Conclusioni

Questa tesi si chiedeva quale architettura funziona meglio in questo dominio, che cosa misura davvero l'errore di ricostruzione, come si colloca il risultato rispetto allo stato dell'arte, e quanto il sistema è vicino a un uso reale.

Sul primo punto, il modello a fotogramma singolo, pensato all'inizio come semplice controllo, si è rivelato in media almeno buono quanto quello su clip. Vedere il movimento aiuta dove l'anomalia è un movimento e la camera è ferma, come su Ped2, ma su Drone-Anomaly molte anomalie si vedono già in un solo fotogramma.

Sul secondo, l'errore di ricostruzione segue soprattutto il contrasto del singolo fotogramma, e solo in parte l'anomalia. Togliere il contrasto porta un solo modello globale da 58,4 a 65,3 in Micro per-scena, e quasi tutto il guadagno si ottiene anche senza riaddestrare, con una divisione per fotogramma. Dove il contrasto è il segno dell'anomalia la correzione peggiora il risultato sette volte su sette, e la relazione che lo prevede è statisticamente significativa. L'entità del guadagno medio è positiva e cresce con un addestramento più lungo, ma per stimarla con precisione servono più scene.

Sul terzo, a parità di protocollo un autoencoder convoluzionale molto più semplice arriva vicino a modelli basati su Transformer: 66,7 contro 67,0 sul protocollo di HSTforU, 68,2 contro 68,6 su quello di ANDT. Con un solo modello globale supera anche il 62,5 dell'autoencoder del benchmark originale. Questo confronto è possibile solo misurando ogni lavoro sul suo protocollo, perché gli stessi punteggi danno numeri distanti fino a quasi trenta punti a seconda di come si aggregano.

Sul quarto, il sistema rileva 22 dei 26 eventi con poco più di un falso allarme ogni mille fotogrammi. La catena di Otsu, con la calibrazione della soglia per video, vale quasi venti punti di falsi positivi. Su video in cui le anomalie non sono rare è già utile. Su filmati reali, dove le anomalie sono rare, nessun metodo pubblicato è ancora pronto, perché il limite è del compito più che del modello.

Il risultato complessivo è che in questo dominio la difficoltà sta soprattutto nel problema, più che nel modello. Drone-Anomaly sta all'estremo sfavorevole di entrambi gli assi, e su UCSD Ped2 la stessa pipeline, senza regolazioni, va molto meglio. La correzione del contrasto funziona proprio perché agisce su questa difficoltà: rende i fotogrammi normali meno diversi fra loro. Per stimare con precisione quanto vale servono più scene e un terzo dominio di difficoltà intermedia, ed è la direzione principale degli sviluppi che seguono.

11.3 Sviluppi futuri

Gli sviluppi proposti nascono dai limiti misurati.

- *Un terzo dominio di difficoltà intermedia.* Con due domini soltanto, il legame fra la variabilità del contrasto e l'utilità della correzione è una retta per due punti.
- *Trovare un modo di applicare la correzione solo dove aiuta*, per esempio scena per scena, seguendo la relazione di trade-off del capitolo 7.
- *Provare la correzione su un modello a predizione*, il paradigma dei tre lavori del benchmark, per vedere se aiuta anche lì. È un esito atteso, perché anche il suo punteggio è una differenza fra pixel, misurata sul fotogramma da predire: dovrebbe quindi crescere con il contrasto di quel fotogramma, come l'errore di un autoencoder (sezione 2.3).
- *Applicare la correzione a modelli più grandi e già addestrati*, come quelli dei tre lavori. La correzione sul punteggio non richiede di riaddestrare, quindi basta applicarla al loro errore per vedere se anche lì il punteggio segue il contrasto.
- *Una mitigazione del difetto sui fotogrammi quasi uniformi*, per esempio con una soglia minima per σ che non tolga il segnale dove il basso contrasto è l'anomalia (sezione 6.5).
- *Separare le riprese con la camera in movimento da quelle con il drone fermo*, per verificare se lo svantaggio del modello 3D si concentra sulle prime. Nello stesso modo si può approfondire il vantaggio del 3D su Farmland (sezione 8.3).

Appendice A

Riproducibilità

Questa appendice raccoglie ciò che serve per ripetere gli esperimenti: la ricetta di addestramento e l'hardware usato.

La ricetta. 128×128 RGB, 5 epoche, Adam con tasso di apprendimento 10^{-3}, perdita quadratica media, seed 42; lotto di 64 fotogrammi per il 2D e di 8 clip per il 3D, clip di 6 fotogrammi estratte ogni 3 in addestramento e ogni 6 in test.

Hardware. Tutti i numeri della tesi sono stati prodotti su MPS, su un MacBook Air con processore Apple M4. L'unica eccezione è il controllo con l'addestramento lungo (sezione 8.4), eseguito su CUDA con una GPU NVIDIA L4. Fra sistemi diversi si confrontano solo le *differenze*, non i valori assoluti. Rieseguire un addestramento su un hardware diverso sposta l'AUC fino a quasi 2 punti su una singola scena, mentre la sola inferenza dallo stesso modello salvato resta sotto il decimo di punto.

Appendice B

Tavole complete

Le quattro tavole che seguono riportano per esteso i numeri che i capitoli citano in forma aggregata. Sono generate direttamente dai dati, senza trascrizione a mano.

Tabella B.1. Il riferimento e le sei normalizzazioni della tabella 8.2, scena per scena, in Micro per-scena. Nessuna normalizzazione vince ovunque: ognuna rimuove dall'errore una statistica diversa, e dove quella statistica conteneva segnale il risultato peggiora. Le celle sotto 50 sono AUC rovesciate.

variante	Bike	Crossroads	Farmland	Highway	Railway	Solar	Vehicle	media
errore grezzo	71,5	45,5	29,8	67,0	54,7	75,2	65,4	58,4
z-score per fotogramma	66,5	49,8	44,6	61,7	84,9	85,5	64,1	65,3
sola centratura	72,0	44,1	29,7	66,5	56,1	76,5	67,7	58,9
min-max per fotogramma	56,4	44,5	26,3	68,3	0,2	77,9	59,0	47,5
BatchNorm nei layer	72,1	43,6	28,9	64,6	60,3	76,1	63,0	58,4
Instance Norm nei layer	74,7	51,7	26,8	57,3	42,0	76,2	49,9	54,1
e/σ^2	69,0	49,8	37,5	63,5	86,0	85,6	60,2	64,5

Tabella B.2. Le AUC per video su UCSD Ped2. La scena è una sola, quindi una lettura per scena non avrebbe senso. Quattro video su dodici sono interamente anomali e non hanno un'AUC: per questo la Macro è calcolata su otto. Il video 01 è l'unico con AUC_σ alta, ed è l'unico con AUC sotto 50 nella coppia 2D.

video	fotogrammi	anomali	2D senza z	2D con z	3D senza z	3D con z	AUC_σ
01	180	120	44,4	41,5	59,8	56,5	99,0
02	180	86	99,8	99,1	99,9	100,0	0,0
03	150	146	97,1	97,6	93,7	95,5	16,4
04	180	150	100,0	100,0	99,8	99,8	28,0
05	150	129	76,3	80,6	86,5	88,1	0,4
06	180	159	78,0	64,9	86,3	82,6	0,4
07	180	135	98,7	98,6	96,7	95,5	0,0
08	180	180	—	—	—	—	—
09	120	120	—	—	—	—	—
10	150	150	—	—	—	—	—
11	180	180	—	—	—	—	—
12	180	93	79,9	89,2	72,1	77,6	40,8

Tabella B.3. Il confronto scena per scena, ciascun blocco con il protocollo dichiarato dal lavoro corrispondente. I valori della colonna *riferimento* sono ricavati dalle tabelle dei rispettivi lavori. L'ultimo blocco è il controllo con l'addestramento lungo della sezione 8.4, eseguito su CUDA.

scena	senza z	z input	z punt.	riferimento
HSTforU (Micro per-scena +minmax)				
Bike	77,6	72,6	74,8	82,7
Crossroads	43,8	57,6	60,5	53,5
Farmland	29,8	44,6	37,5	60,8
Highway	84,2	61,7	65,0	70,6
Railway	54,7	84,9	86,0	67,8
Solar	48,5	80,8	81,8	67,7
Vehicle	68,2	62,2	61,4	65,6
media	58,1	66,4	66,7	67,0
FTDMamba (intero dataset)				
Micro dataset +minmax	68,5	69,2	69,8	71,6
Micro dataset +minmax (PSNR)	64,8	65,2	66,4	71,6
Macro per-video	58,1	62,7	64,2	72,3
ANDT (Micro per-scena, 13 modelli per sequenza)				
Bike	78,5	78,4	78,2	CAE 59,4 / ANDT 82,2
Crossroads	53,5	68,5	68,9	CAE 57,7 / ANDT 65,2
Farmland	31,6	32,7	33,5	CAE 77,1 / ANDT 79,5
Highway	68,0	62,2	61,7	CAE 58,3 / ANDT 68,7
Railway	62,9	90,8	94,0	CAE 61,2 / ANDT 59,4
Solar	76,5	86,5	87,5	CAE 62,9 / ANDT 64,2
Vehicle	70,2	55,8	53,9	CAE 60,9 / ANDT 61,3
media	63,0	67,9	68,2	CAE 62,5 / ANDT 68,6
ANDT (Micro per-scena, 1 modello globale)				
Bike	71,5	66,5	69,0	CAE 59,4 / ANDT 82,2
Crossroads	45,5	49,8	49,8	CAE 57,7 / ANDT 65,2
Farmland	29,8	44,6	37,5	CAE 77,1 / ANDT 79,5
Highway	67,0	61,7	63,5	CAE 58,3 / ANDT 68,7
Railway	54,7	84,9	86,0	CAE 61,2 / ANDT 59,4
Solar	75,2	85,5	85,6	CAE 62,9 / ANDT 64,2
Vehicle	65,4	64,1	60,2	CAE 60,9 / ANDT 61,3
media	58,4	65,3	64,5	CAE 62,5 / ANDT 68,6
Addestramento lungo (40 epoche, CUDA)				
Micro per-scena +minmax	53,3	64,5	64,6	HSTforU 67,0
Micro per-scena	54,5	67,1	65,3	ANDT 68,6
Micro dataset +minmax	71,6	72,1	74,8	FTDMamba 71,6
Micro dataset +minmax (PSNR)	68,7	69,2	73,3	FTDMamba 71,6
Macro per-video	58,0	64,7	63,2	FTDMamba 72,3

Tabella B.4. Le metriche a soglia nel regime *a priori*, scena per scena e variante per variante. Si vedono i due problemi opposti descritti nella sezione 9.2: su Farmland la soglia non intercetta un solo fotogramma anomalo, su Railway li segnala tutti. Il trattino segnala una metrica non definita, cioè nessuna segnalazione.

variante	scena	recall	precision	F1	OA	FPR
2D senza z	Bike	76,1	75,2	75,6	68,0	47,2
	Crossroads	44,0	23,4	30,5	45,9	53,5
	Farmland	0,0	0,0	—	49,4	48,9
	Highway	25,1	16,1	19,7	63,8	28,0
	Railway	100,0	7,7	14,3	7,9	99,8
	Solar	76,8	55,4	64,3	72,5	29,5
	Vehicle	80,0	39,6	53,0	47,6	71,4
	aggregato	71,2	54,1	61,5	59,9	49,3
2D con z	Bike	65,3	76,8	70,6	64,5	37,0
	Crossroads	63,5	30,6	41,3	51,2	53,4
	Farmland	0,0	0,0	—	87,5	9,5
	Highway	25,1	16,1	19,7	63,8	28,0
	Railway	100,0	7,7	14,3	7,7	100,0
	Solar	76,8	67,1	71,6	80,3	18,0
	Vehicle	25,6	54,7	34,9	64,7	12,4
	aggregato	61,9	58,8	60,3	63,4	35,4
3D senza z	Bike	54,8	78,6	64,6	60,8	28,0
	Crossroads	36,7	25,6	30,2	54,0	39,6
	Farmland	0,0	0,0	—	65,8	31,9
	Highway	50,8	29,1	37,0	69,5	26,5
	Railway	100,0	7,7	14,3	7,9	99,8
	Solar	9,8	12,6	11,1	48,6	32,8
	Vehicle	25,1	58,0	35,0	65,5	10,7
	aggregato	48,7	54,8	51,6	58,9	32,9
3D con z	Bike	48,8	79,2	60,4	58,2	24,1
	Crossroads	0,8	10,1	1,4	71,3	2,5
	Farmland	0,0	0,0	—	87,2	9,8
	Highway	17,7	17,2	17,5	70,5	18,2
	Railway	100,0	7,8	14,5	9,0	98,7
	Solar	59,3	63,7	61,4	75,8	16,2
	Vehicle	19,2	77,3	30,8	68,0	3,3
	aggregato	41,5	66,1	51,0	64,1	17,4

Bibliografia

[1] Bao, T., Chen, J., Li, W., Wang, X., Fei, J., Wu, L., Zhao, R. e Zheng, Y. MIAD: A maintenance inspection dataset for unsupervised anomaly detection. In *IEEE/CVF International Conference on Computer Vision Workshops (ICCVW)*, pp. 993–1002 (2023). doi:10.1109/ICCVW60793.2023.00106.

[2] Bergmann, P., Fauser, M., Sattlegger, D. e Steger, C. MVTec AD — a comprehensive real-world dataset for unsupervised anomaly detection. In *IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 9584–9592 (2019). doi:10.1109/CVPR.2019.00982.

[3] Ioffe, S. e Szegedy, C. Batch normalization: Accelerating deep network training by reducing internal covariate shift. In *International Conference on Machine Learning (ICML)*, vol. 37 di *Proceedings of Machine Learning Research*, pp. 448–456 (2015). arXiv:1502.03167.

[4] Jin, P., Mou, L., Xia, G.-S. e Zhu, X. X. Anomaly detection in aerial videos with transformers. *IEEE Transactions on Geoscience and Remote Sensing*, **60** (2022), 1–13. doi:10.1109/TGRS.2022.3198130.

[5] Kingma, D. P. e Ba, J. Adam: A method for stochastic optimization. In *International Conference on Learning Representations (ICLR)* (2015). arXiv:1412.6980.

[6] Le, V.-T., Jin, H. e Kim, Y.-G. HSTforU: anomaly detection in aerial and ground-based videos with hierarchical spatio-temporal transformer for U-net. *Applied Intelligence*, **55** (2025), 261. doi:10.1007/s10489-024-06042-4.

[7] Liu, C.-Z., Chen, S.-B., Shu, Q.-L., Ding, C., Tang, J. e Luo, B. FTDMamba: Frequency-assisted temporal dilation Mamba for unmanned aerial vehicle video anomaly detection. Preprint (2026). arXiv:2601.11254.

[8] Mahadevan, V., Li, W., Bhalodia, V. e Vasconcelos, N. Anomaly detection in crowded scenes. In *IEEE Computer Society Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 1975–1981 (2010). doi:10.1109/CVPR.2010.5539872.

[9] Otsu, N. A threshold selection method from gray-level histograms. *IEEE Transactions on Systems, Man, and Cybernetics*, **9** (1979), 62–66. doi:10.1109/TSMC.1979.4310076.

[10] Ulyanov, D., Vedaldi, A. e Lempitsky, V. Instance normalization: The missing ingredient for fast stylization. Preprint (2016). `arXiv:1607.08022`.